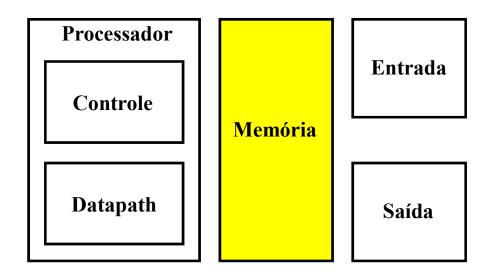
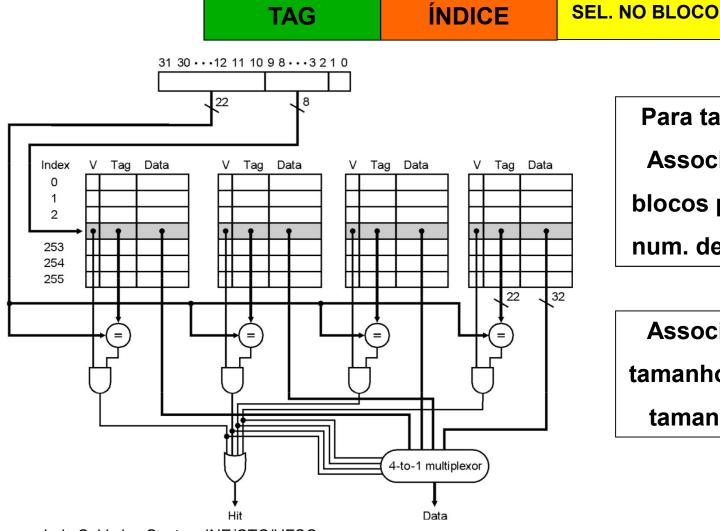
Cache: Associatividade e múltiplos níveis



Organização de uma cache n-way



Para tamanho fixo:

Associatividade 1

blocos p/ conjunto ↑

num. de conjuntos ↓

Associatividade 1

tamanho do índice 🗸

tamanho do tag 1

Tag versus associatividade

- Hipótese:
 - Cache com 4K blocos
 - 4 palavras/bloco
 - Endereço de 32 bits
- Quatro cenários de mapeamento:
 - Direto, 2-way, 4-way e totalmente associativa
- Tag + indice + offset
 - 4 palavras/bloco = 2⁴ bytes/bloco
 - -Restam 32 4 = 28 bits (tag + indice)

Tag versus associatividade

- Número de conjuntos
 - Direto: 4K conjuntos (índice = 12)
 - 2-way: 2K conjuntos (índice = 11)
 - 4-way: 1K conjuntos (índice = 10)
 - -T.A.: 1 conjunto (indice = 0)
- Número de bits gastos com tag
 - Direto: $(28-12) \times 1 \times 4K = 64Kbits$
 - -2-way: (28-11) x 2 x 2K = 68Kbits
 - -4-way: (28-10) x 4 x 1K = 72Kbits
 - -T.A.: (28-0) x 4K x 1 = 112Kbits

Política de atualização da cache

- Precisa-se armazenar um dado na cache...
 - Mas nenhuma posição livre.
 - Qual bloco substituir ?
- Mapeamento direto:
 - Bloco ocupando posição mapeada <u>precisa</u> ser substituído
- Cache n-way:
 - Critério de escolha mais popular
 - » Bloco não usado há mais tempo é substituído
 - » LRU ("least recently used")

$$ciclos_{stall} = \frac{acessos}{programa} \times mr \times penalidade$$

Sejam:

- -I = número de instruções;
- -LS = proporção de load + store no "mix";
- -acessos/programa = I + LS \times I = I (1+ LS);
- $-CPI_{stall} = ciclos_{stall} / I;$
- CPI = CPI_{ideal} + CPI_{stall}
- Supondo CPI_{ideal} = 1:

$$CPI = 1 + (1 + LS) \times mr \times penalidade$$

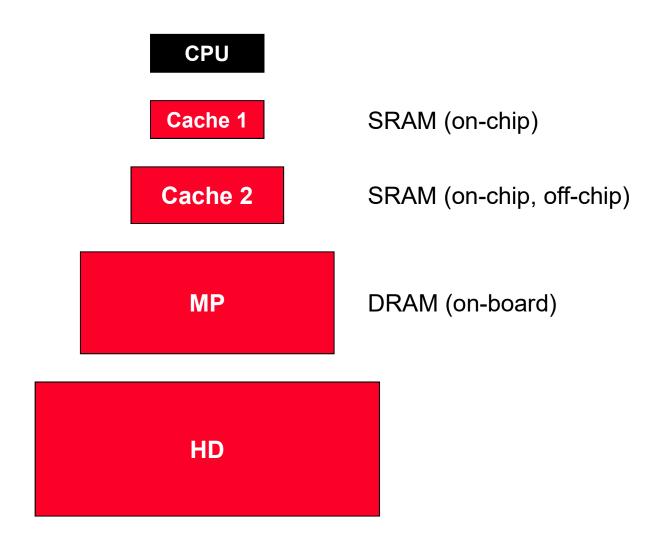
- Dado um tamanho fixo de cache...
 - Mais palavras por bloco:
 - » Maior captura da localidade espacial (↓mr)
 - Mais associatividade:
 - » Maior captura da localidade temporal (↓mr)
 - Nenhum impacto na penalidade !?

$$CPI = 1 + (1 + LS) \times mr \times penalidade$$

- Tendências tecnológicas até 2005:
 - f_r crescia rapidamente, mas f_{acesso} (DRAM) lentamente.
- Problema:
 - Penalidade de falta tendia a aumentar.
- Solução: dois níveis de cache (L1 e L2)
 - Quando comparada a cache única de mesma capacidade...
 - Objetivo 1: reduzir tempo de acerto e minimizar T
 - » L1: precisa ser pequena para ser rápida
 - » L1: maior taxa de faltas, mas penalidade compensada por L2
 - Objetivo 2: reduzir penalidade e taxa global de faltas
 - » L2: pode ser maior, pois não afeta tempo de acerto nem T
 - » L2: menor taxa de faltas local, mas oferece menor penalidade

$$CPI = 1 + (1 + LS) \times mr \times penalidade$$

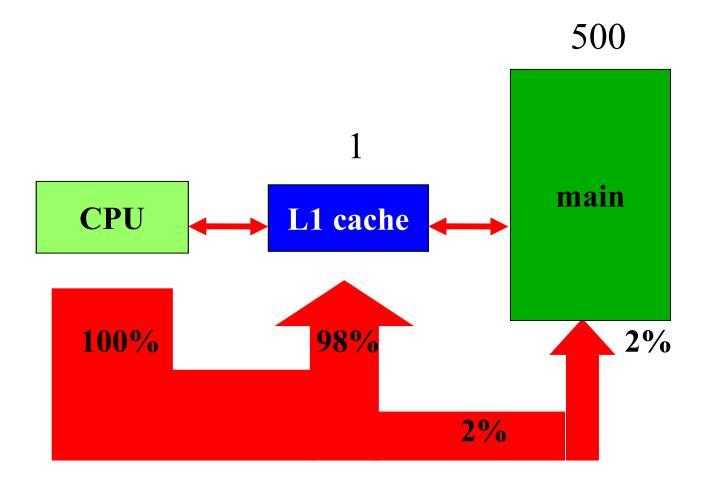
Redução da penalidade



Exemplo

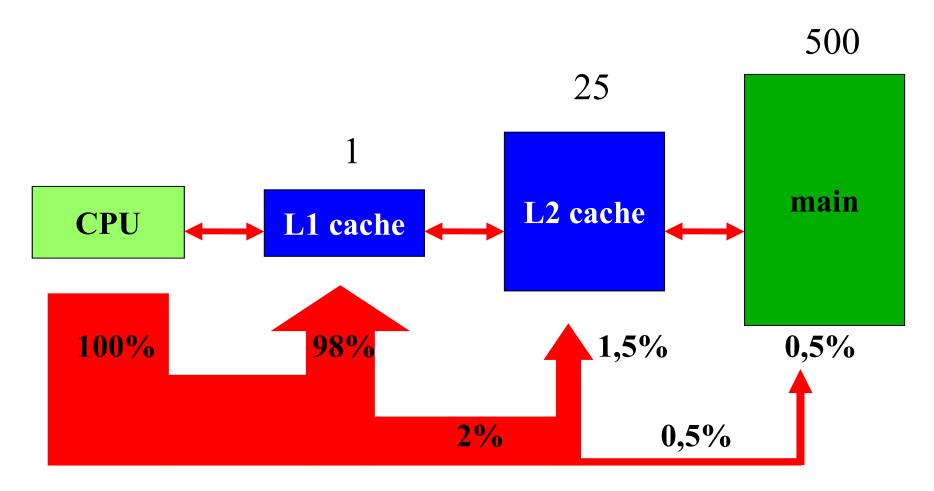
- Impacto da cache secundária
 - -f = 5GHz (T = 0.2ns)
 - Primária: 0,2ns, taxa de faltas = 2%
 - Secundária: 5ns, taxa global de faltas = 0,5%
 - Memória principal: 100ns
- Hipóteses:
 - Só acesso a instruções;
 - $-CPI_{ideal} = 1.$
- Comparação:
 - Qual o CPI só com a cache primária?
 - Qual o CPI para dois níveis de cache ?

Uma única cache



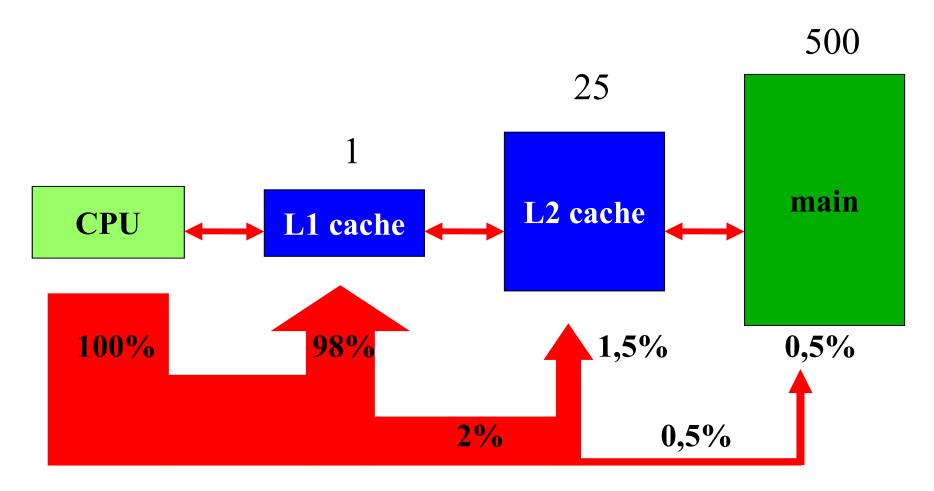
$$CPI = 1 + 0.02 \times 500 = 11$$

Dois níveis de cache



$$CPI = 1 + 0.02 \times 25 + 0.005 \times 500 = 4.0$$

Dois níveis de cache



$$CPI = 1 + 0.015 \times 25 + 0.005 \times 525 = 4.0$$

Um panorama contemporâneo



L2=256KB

L3=8MB

(e.g. Intel Xeon, AMD Opteron)

Servers

Barcelona:

L1=64KB+64KB

L2=512KB

L3=2MB

A15: R7:

L1=32KB+32KB L1=64KB+64KB

L2= up to 4MB



SRAM=1MB+1MB

(sem cache)



MCUs

(e.g. ARM M1)



SoC

(e.g. Qualcomm Snapdragon, Samsumg Exynos)

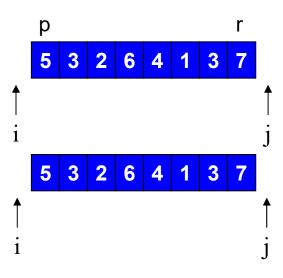
- Dois programas de ordenação
 - Diferentes números de itens a ordenar (4K a 4M)
- Algoritmos com complexidades distintas
 - QuickSort: O(n log n) [média]
 - RadixSort: O(n) [média]*
- Complexidade:
 - Comportamento assintótico
 - » Número de operações como função da entrada (n)
 - » Para um n grande
- Desempenho
 - Número de instruções e número de ciclos

```
QUICKSORT(A,p,r)
if p< r
    then
             q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
i \leftarrow r + 1
while TRUE
    do
                         j \leftarrow j - 1
             repeat
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```

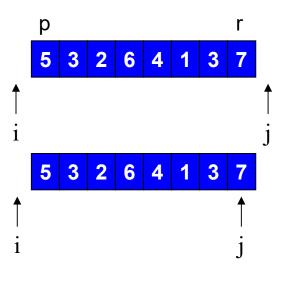
p

(Fonte: T. Cormen, C. Leiserson, R. Rivest, "Introduction to Algorithms", MIT Press.)

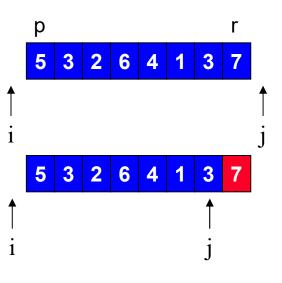
```
QUICKSORT(A,p,r)
if p< r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                        j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



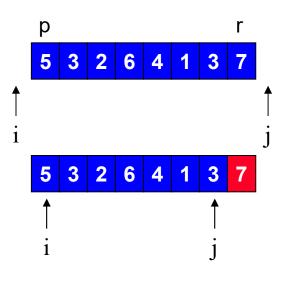
```
QUICKSORT(A,p,r)
if p< r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                        j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



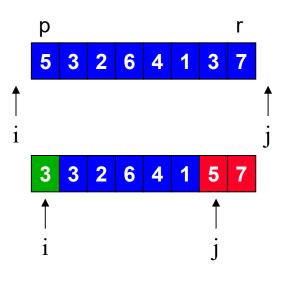
```
QUICKSORT(A,p,r)
if p< r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                        j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



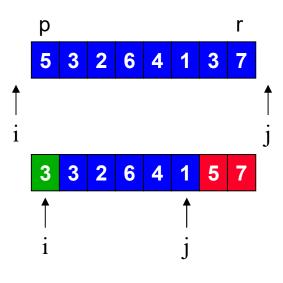
```
QUICKSORT(A,p,r)
if p< r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                        j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



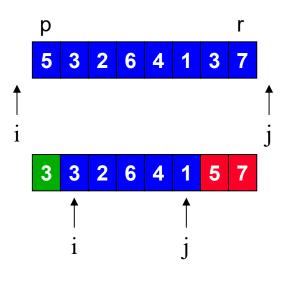
```
QUICKSORT(A,p,r)
if p< r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                        j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



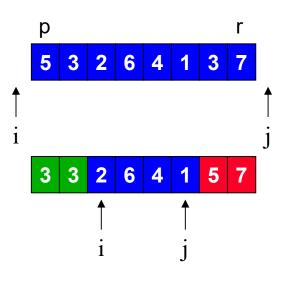
```
QUICKSORT(A,p,r)
if p< r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                        j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



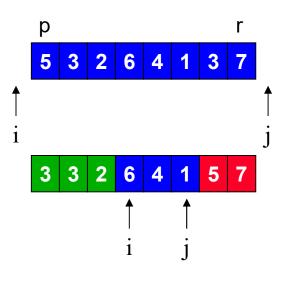
```
QUICKSORT(A,p,r)
if p< r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                        j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



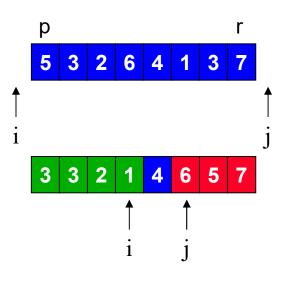
```
QUICKSORT(A,p,r)
if p < r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                         j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



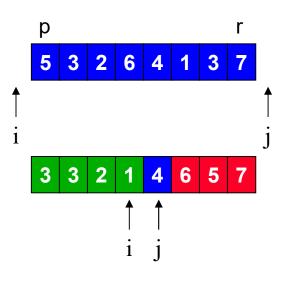
```
QUICKSORT(A,p,r)
if p < r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                         j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



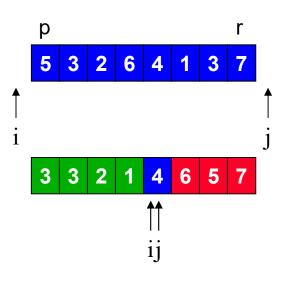
```
QUICKSORT(A,p,r)
if p < r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                        j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



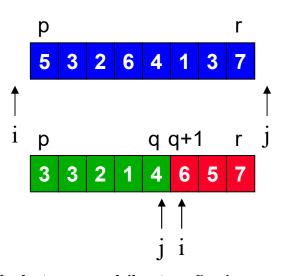
```
QUICKSORT(A,p,r)
if p < r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                         j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



```
QUICKSORT(A,p,r)
if p < r
    then
            q \leftarrow PARTITION(A,p,r)
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
j \leftarrow r + 1
while TRUE
    do
             repeat
                        j \leftarrow j - 1
                          until A[j] \le x
                         i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



```
QUICKSORT(A,p,r)
if p< r
             q \leftarrow PARTITION(A,p,r)
    then
             QUICKSORT(A,p,q)
             QUICKSORT(A,q+1,r)
PARTITION(A,p,r)
x \leftarrow A[p]
i \leftarrow p-1
i \leftarrow r + 1
while TRUE
    do
                          i \leftarrow i - 1
             repeat
                          until A[i] \le x
                          i \leftarrow i + 1
              repeat
                          until A[i] \ge x
             if i < j
                          then exchange A[i] \leftrightarrow A[j]
                          else return j
```



Localidade temporal (instruções)

Grande: recursividade e laços

Localidade espacial (instruções)

Pouca: BBs pequenos

Localidade espacial (dados)

Grande: i e j percorrem arranjo sequencialmente

Localidade temporal (dados)

Grande: partições são revisitadas

COUNTING-SORT(A,B,k)

for
$$i \leftarrow 1$$
 to k

do $C[i] \leftarrow 0$

for $j \leftarrow 1$ to length[A]

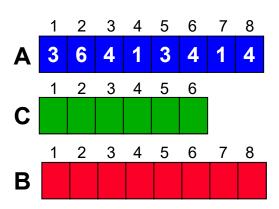
do $C[A[j]] \leftarrow C[A[j]] + 1$

for $i \leftarrow 2$ to k

do $C[i] \leftarrow C[i] + C[i-1]$

for $j \leftarrow length[A]$ downto 1

do $B[C[A[j]]] \leftarrow A[j]$
 $C[A[j]] \leftarrow C[A[j]] - 1$



Radix Sort requer método auxiliar de ordenação estável. Por exemplo: Counting Sort
Hipótese de Counting Sort: Elementos a ordenar são inteiros no intervalo de 1 a k

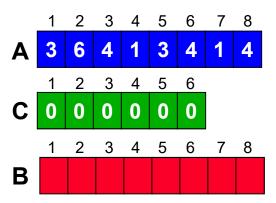
(Fonte: T. Cormen, C. Leiserson, R. Rivest, "Introduction to Algorithms", MIT Press.)

Estado inicial

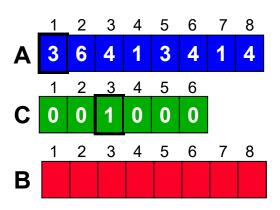
COUNTING-SORT(A,B,k)

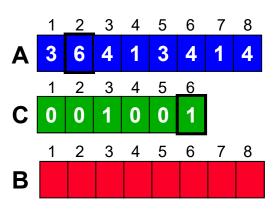
for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

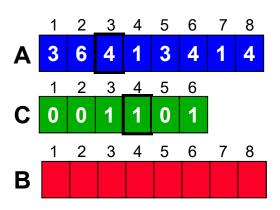
do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$

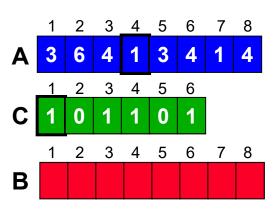


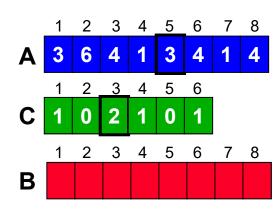
C inicializado

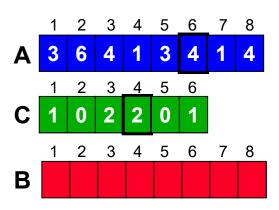


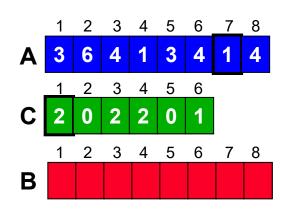


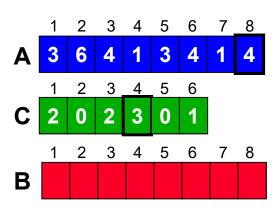








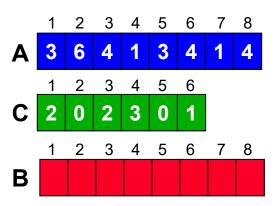




COUNTING-SORT(A,B,k)

for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$

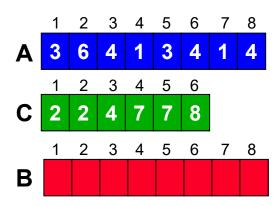


C[i] contém o número de elementos iguais a i

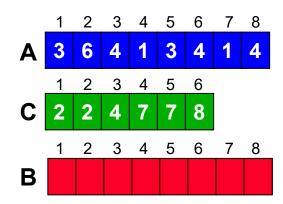
COUNTING-SORT(A,B,k)

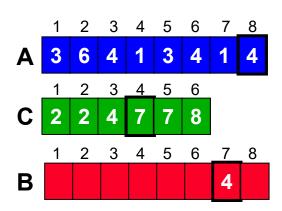
for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$



C[i] contém o número de elementos iguais ou menores a i

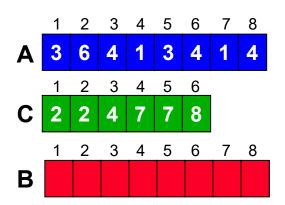


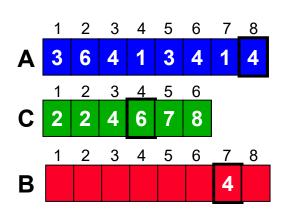


COUNTING-SORT(A,B,k)

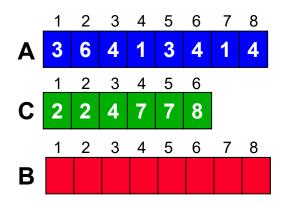
for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

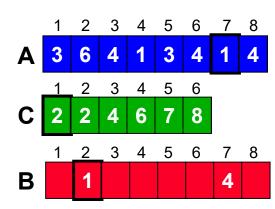
do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$





Ao final da primeira iteração do último laço

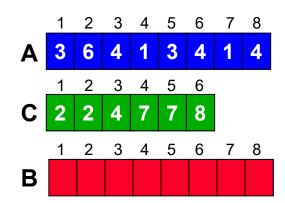


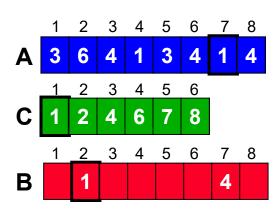


COUNTING-SORT(A,B,k)

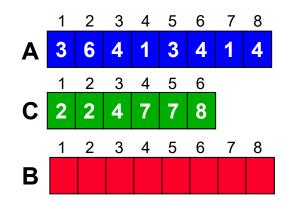
for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

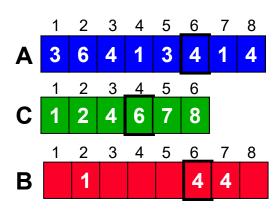
do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow$ length[A] downto 1do $B[C[A[j]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$





Ao final da segunda iteração do último laço

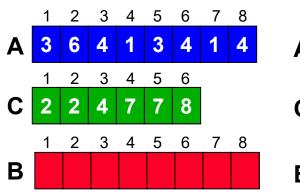


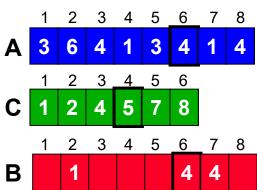


COUNTING-SORT(A,B,k)

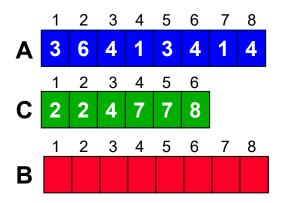
for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

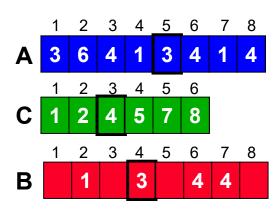
do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]] \leftarrow C[A[j]] - 1$





Ao final da terceira iteração do último laço

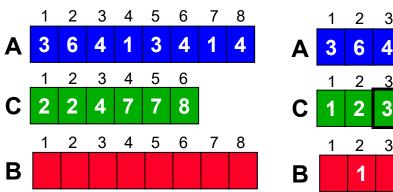


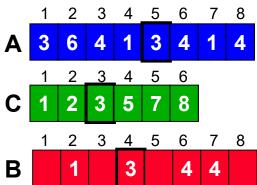


COUNTING-SORT(A,B,k)

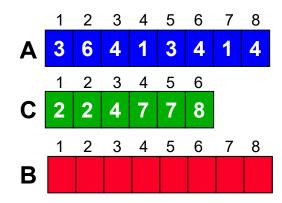
for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

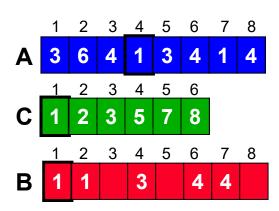
do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$





Ao final da quarta iteração do último laço

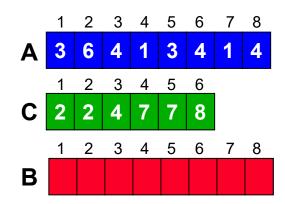


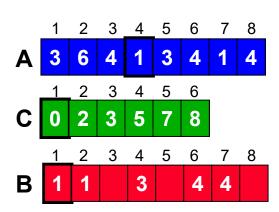


COUNTING-SORT(A,B,k)

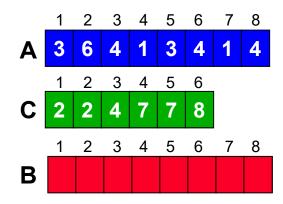
for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

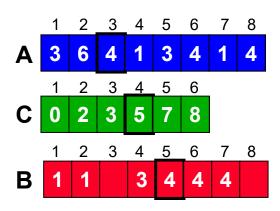
do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$





Ao final da quinta iteração do último laço

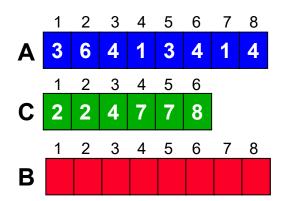


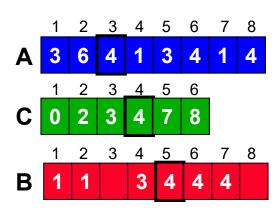


COUNTING-SORT(A,B,k)

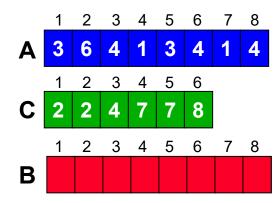
for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

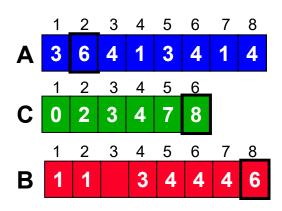
do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$





Ao final da sexta iteração do último laço

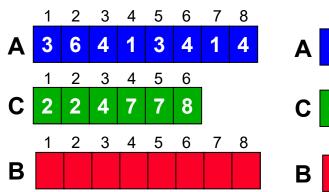


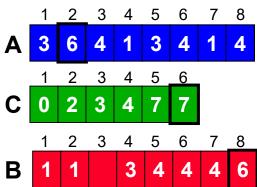


COUNTING-SORT(A,B,k)

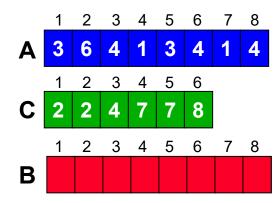
for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

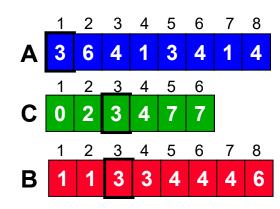
do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$





Ao final da sétima iteração do último laço

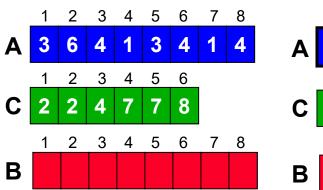


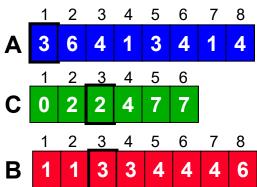


COUNTING-SORT(A,B,k)

for $i \leftarrow 1$ to kdo $C[i] \leftarrow 0$ for $j \leftarrow 1$ to length[A]

do $C[A[j]] \leftarrow C[A[j]] + 1$ for $i \leftarrow 2$ to kdo $C[i] \leftarrow C[i] + C[i-1]$ for $j \leftarrow length[A]$ downto 1do $B[C[A[j]] \leftarrow A[j]$ $C[A[j]] \leftarrow C[A[j]] - 1$

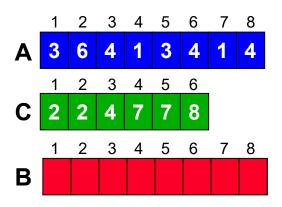


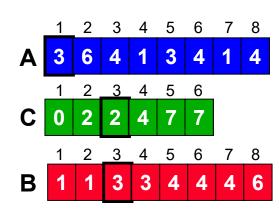


Ao final da última iteração do último laço

COUNTING-SORT(A,B,k)

for
$$i \leftarrow 1$$
 to k
do $C[i] \leftarrow 0$
for $j \leftarrow 1$ to length[A]
do $C[A[j]] \leftarrow C[A[j]] + 1$
for $i \leftarrow 2$ to k
do $C[i] \leftarrow C[i] + C[i-1]$
for $j \leftarrow length[A]$ downto 1
do $B[C[A[j]]] \leftarrow A[j]$





RADIX-SORT(A,d)

for $i \leftarrow 1$ to d

do use COUNTING-SORT to sort A on digit i

 $C[A[i]] \leftarrow C[A[i]] - 1$

Requer mais memória por item a ordenar do que QuickSort Localidade temporal (instruções)

Grande: laços

Localidade espacial (instruções)

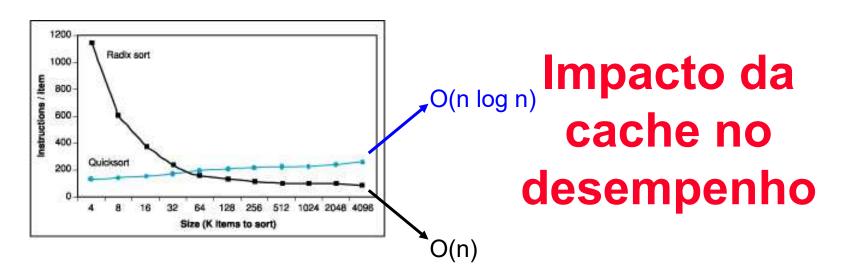
Pouca: BBs pequenos

Localidade espacial (dados)

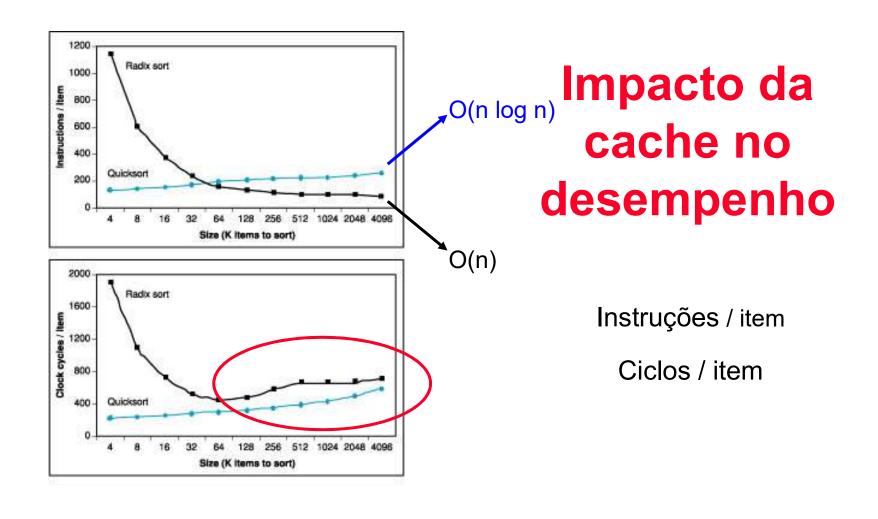
Pequena: só um dos arranjos sequencialmente*

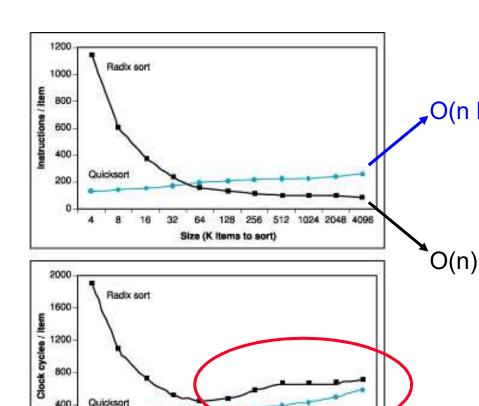
Localidade temporal (dados)

Média: C e A são revisitados várias vezes



Instruções / item





lmpacto da cache no desempenho

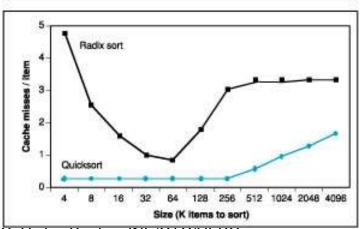
Instruções / item

Ciclos / item

Faltas / item

Maior número de ciclos gastos por item deve-se à menor localidade de RadixSort

Otimizar para a cache: algoritmo e compilador



Size (K items to sort)

128 256 512 1024 2048 4098

Aumentar desempenho via cache

- Desenvolvedor de SW
 - Escolha de algoritmo "cache friendly"
 - Implementação "cache aware"
 - » Ex. Linguagem aloca matrizes por linha, código deve ser ajustado para percorrer linhas (colunas)
 - Otimizações de compilador
- Projetista do sistema computacional
 - Seleção de parâmetros da cache para aplicação
 - » Capacidade, associatividade, tamanho de bloco, níveis
 - Algoritmo, implementação, compilador

Conclusão

- Soluções para aumentar desempenho:
 - Aumento da associatividade
 - » Impacta mr
 - Múltiplos níveis de cache
 - » Impacta penalidade
 - Algoritmos e compiladores "cache-conscientes"
 - » Impactam mr