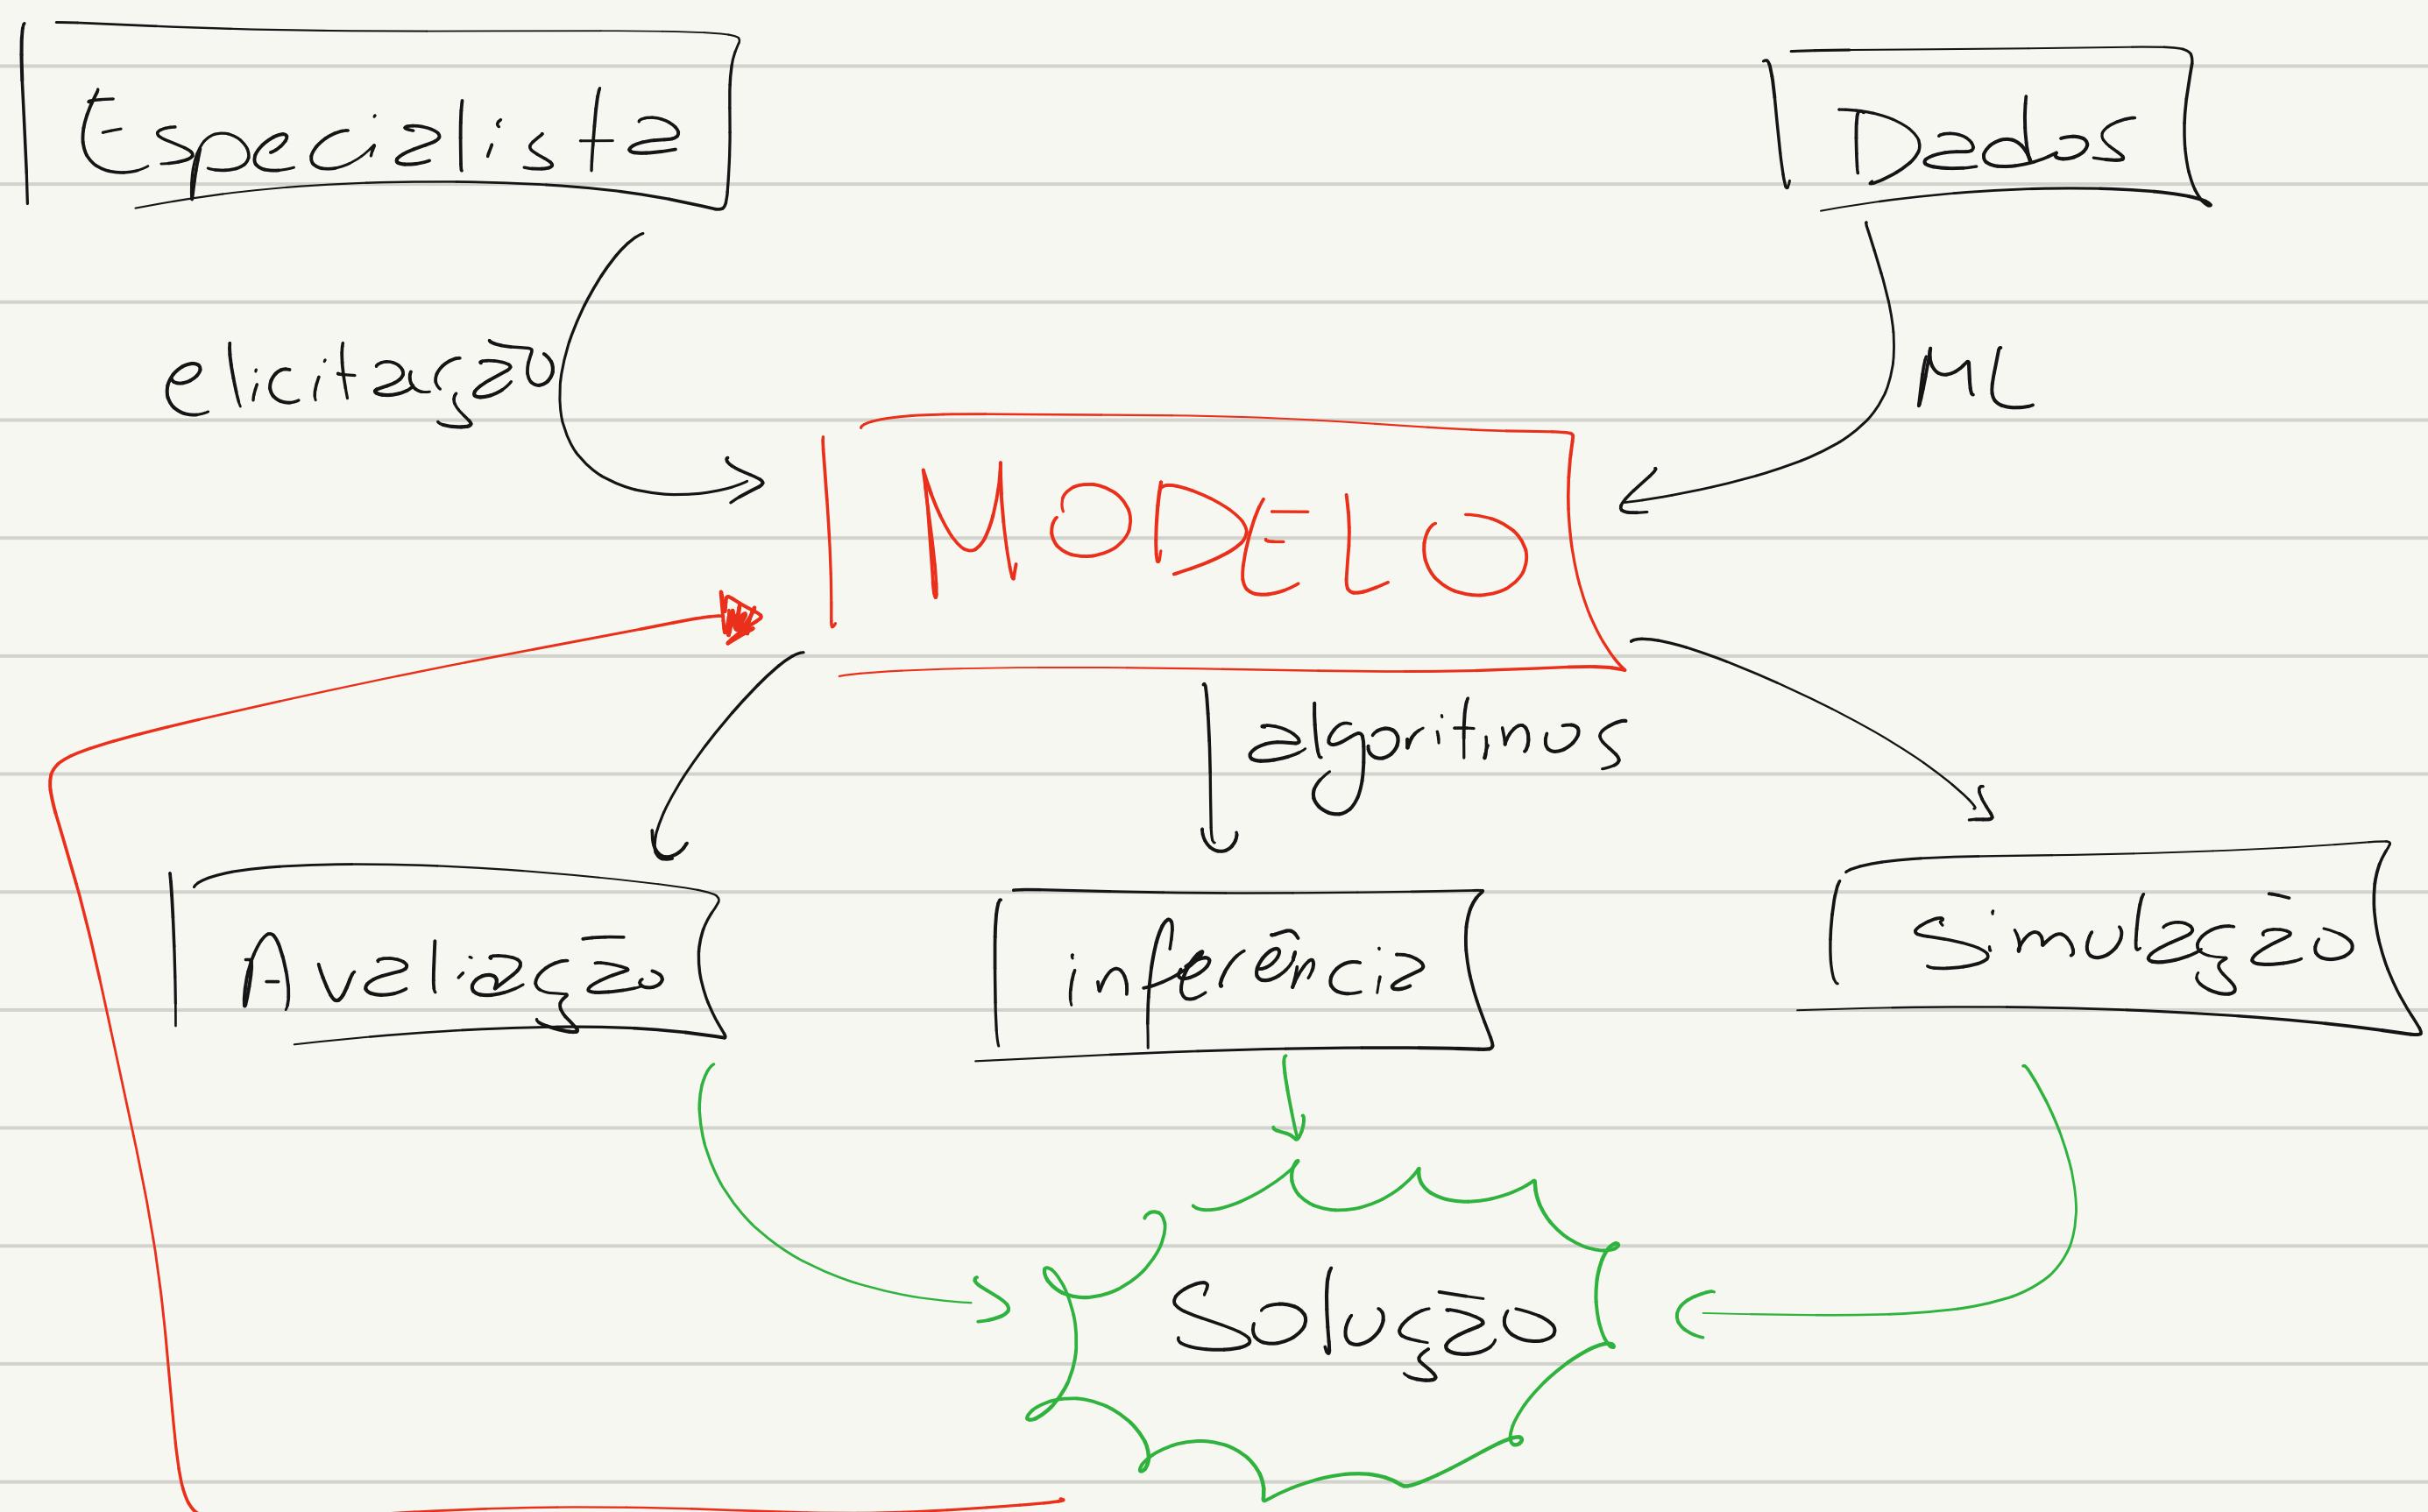


TRATAMENTO DE INCERTEZAS



- Modelos perfeitos exigem muito conhecimento
→ quase impossível {
 - conhecimento preciso
 - ruídos
 - Aleatoriedade};

Modelo imperfeito → INCERTEZA

ALEATORIEDADE: Eventos imprevisíveis; tratado com teoria da probabilidade clássica

IMPRECISÃO: Conceitos mal definidos na observação, impreciso de mediidores; tratado com teoria dos conjuntos fuzzy

IGNORÂNCIA: imprecisão fraca

RACIOCÍNIO PROBABILÍSTICO

- O mais antigo tratamento de incerteza

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \rightarrow P(A) \cdot P(B)$$

TEOREMA DE BAYES

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

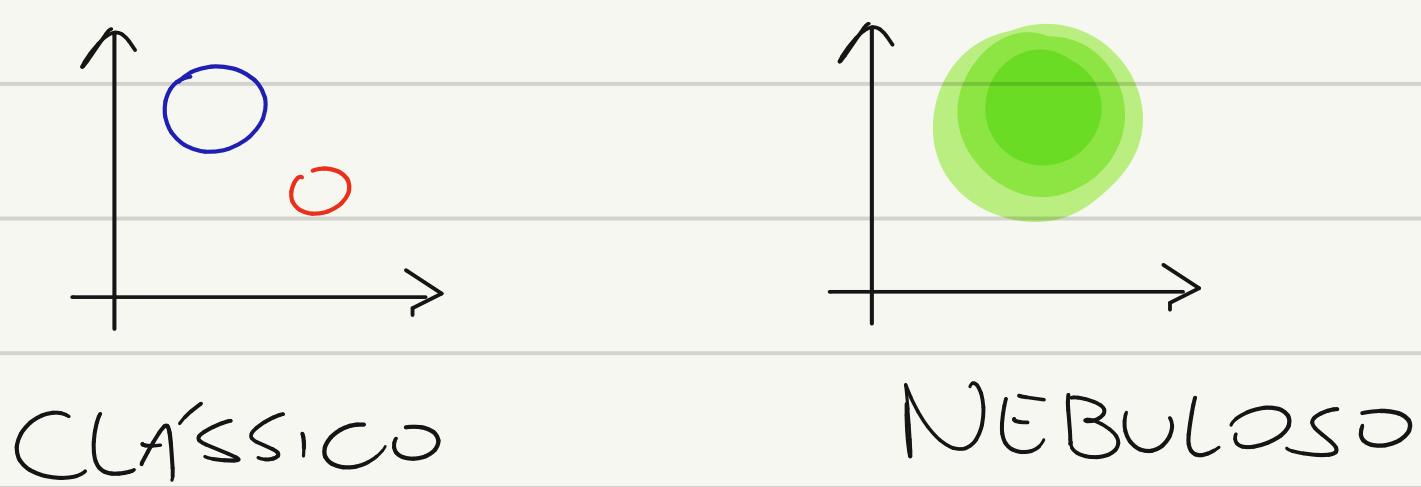
$$P(\text{CAUSA}, \text{EFEITO}_1, \dots, \text{EFEITO}_N) =$$

$$P(\text{CAUSA}) \cdot P(\text{EFEITO}_1 | \text{CAUSA}) + \dots + P(E_n | C)$$

LOGICA NEBULOSA (FUZZY)

- Lógica multivalorada

- Objetivo → fazer com que decisões de máq. se aproximem de decisões de humanos
Conjuntos



CONJUNTO NEBULOSO

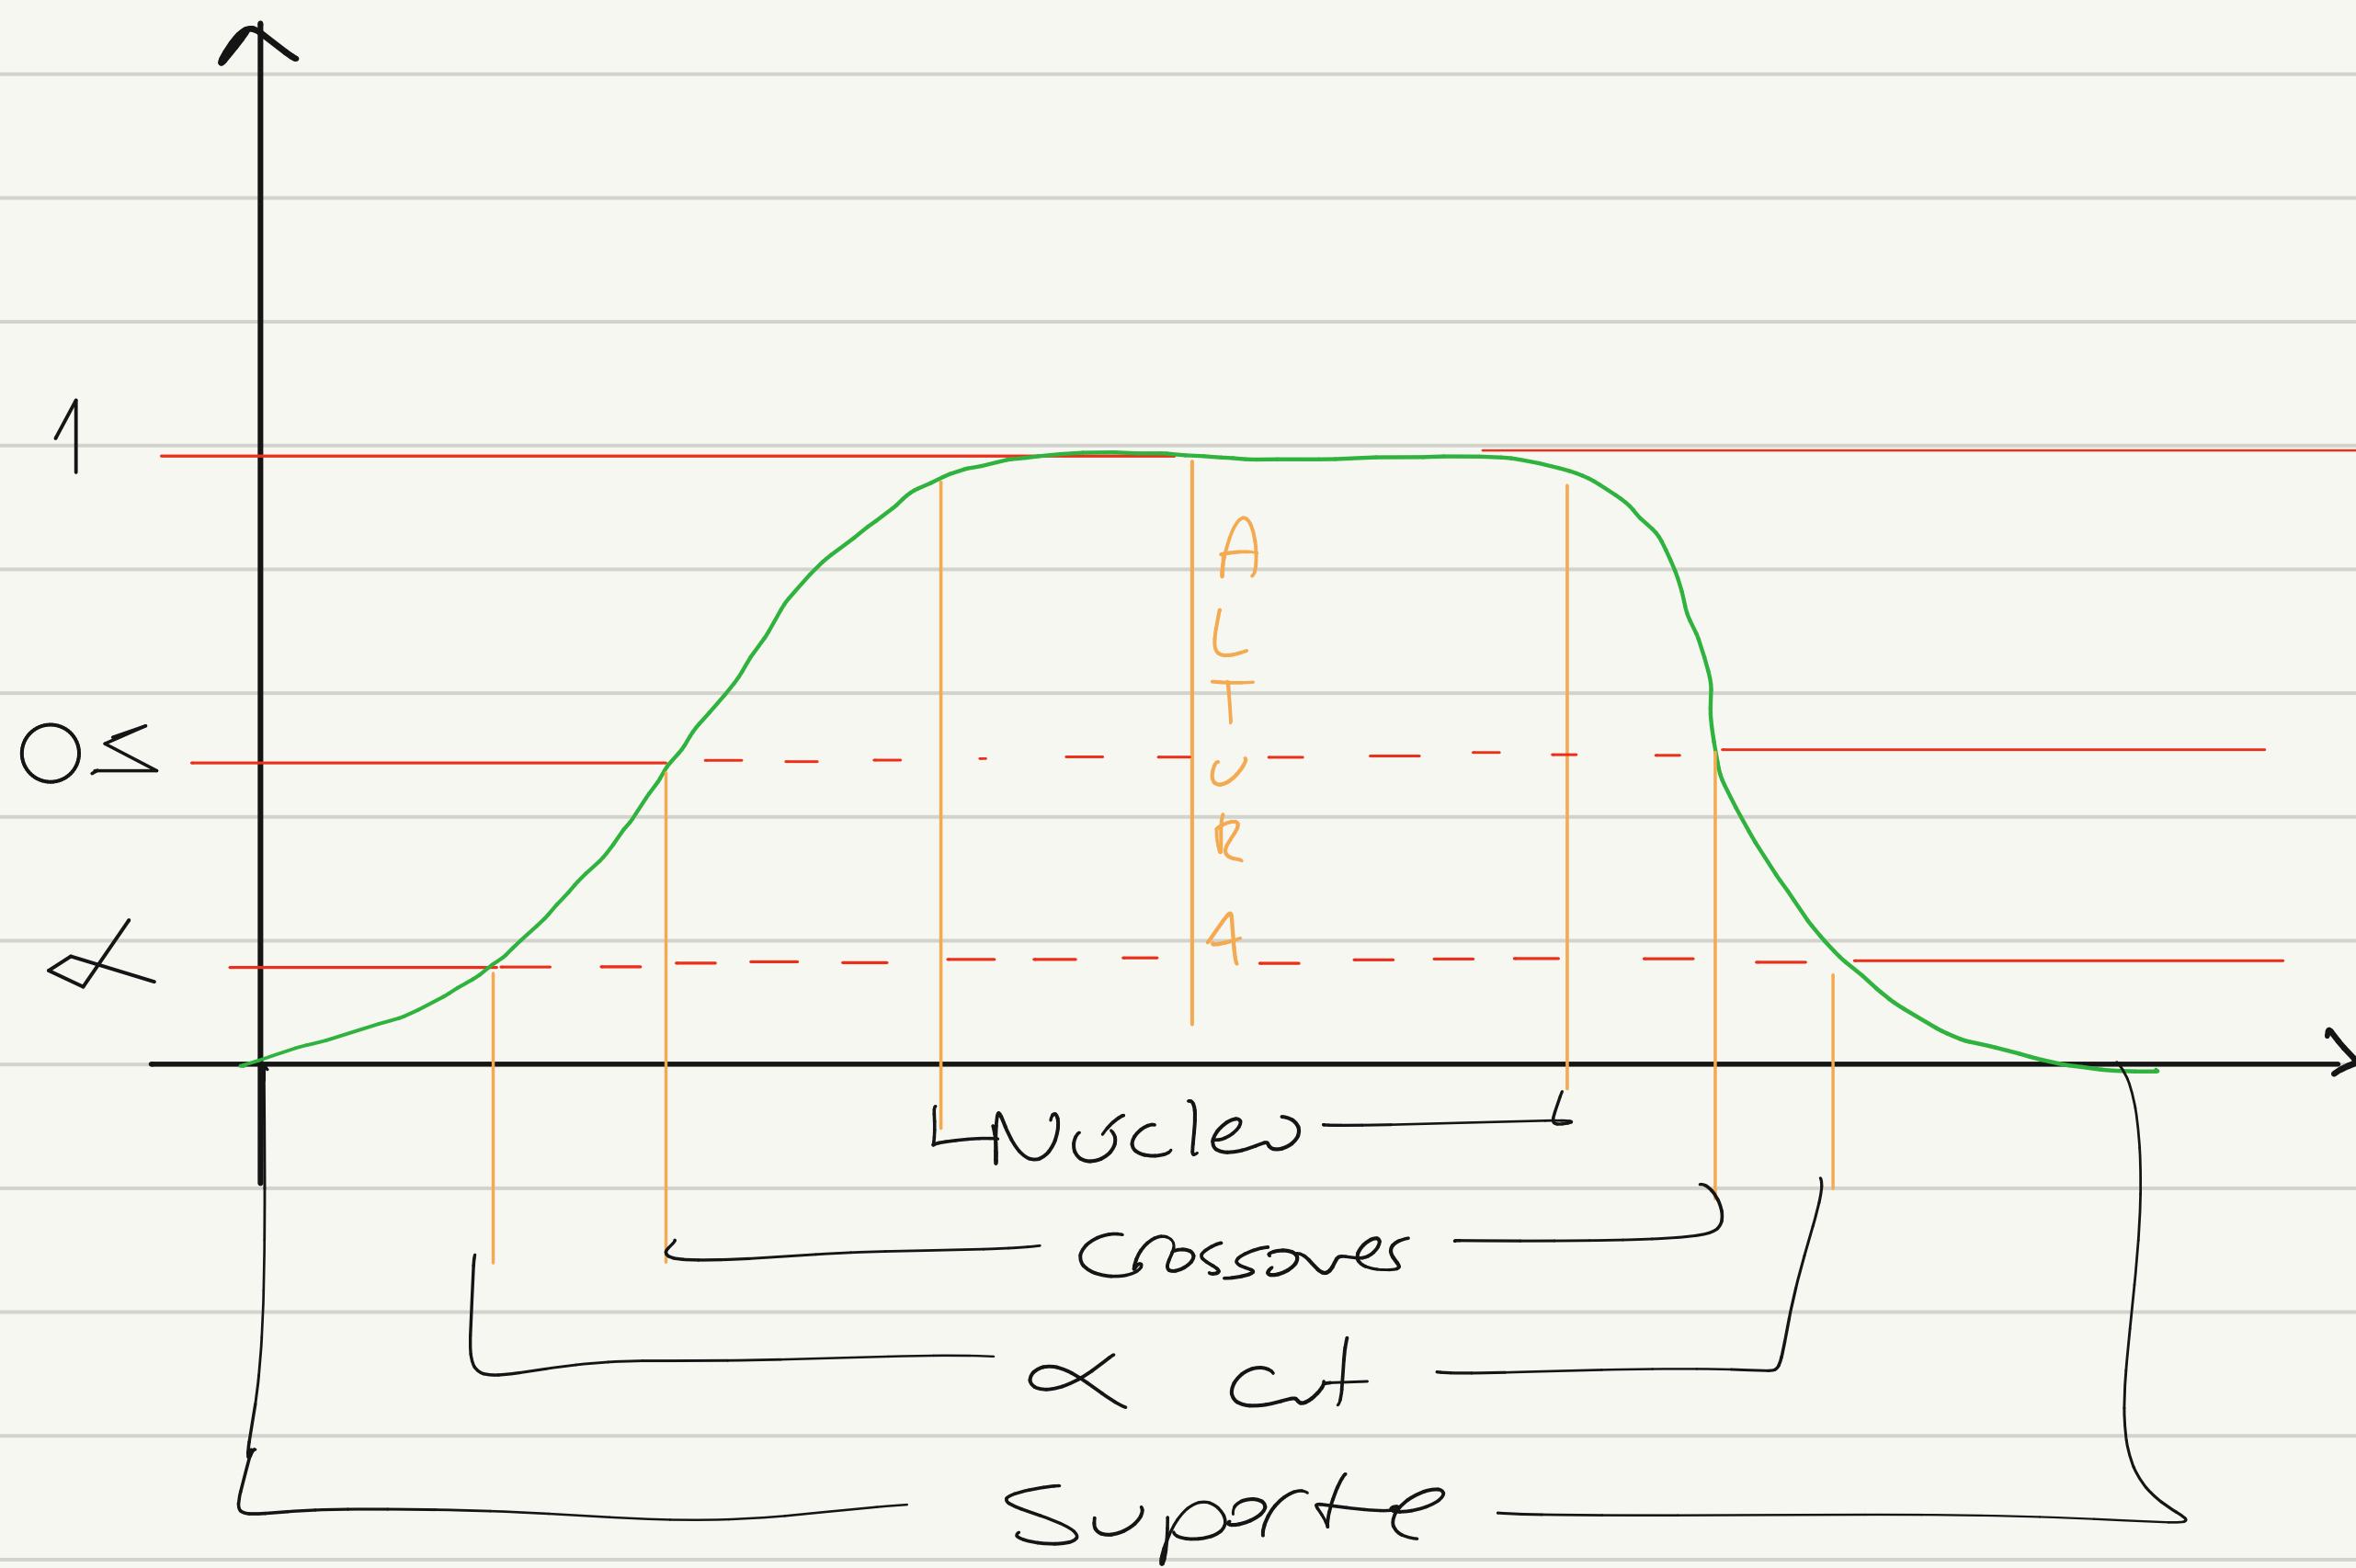
$$A = \{ (x, \mu_A(x)) \mid x \in X \}$$

↳ universo
↳ func. de pertinencia
↳ conjunto

$$\mu_A(x) \rightarrow [0, 1] \text{ ou } 0\% \approx 100\%$$

Possibilidade do elemento
fazer parte do conjunto

- Normalidade $\rightarrow \mu_A(x) = 1$
- Altura $\rightarrow \max_x \mu_A(x)$
- Suporte $\rightarrow \{x \mid \mu_A(x) > 0 \text{ e } x \in X\}$
- Núcleo $\rightarrow \{x \mid \mu_A(x) = 1 \text{ e } x \in X\}$
- Crossover $\rightarrow \{x \mid \mu_A(x) = 0.5\}$
- α cut $\rightarrow A_\alpha : \{x \mid \mu_A(x) \geq \alpha, x \in X\}$
- Strong α cut $\rightarrow A_{\alpha^+} : \{x \mid \mu_A(x) > \alpha, x \in X\}$



Subconjunto $\rightarrow A \subset B$ se $\mu_B(x) \geq \mu_A(x) \forall x \in X$
 igualdade $\rightarrow A = B$ se $\mu_B(x) = \mu_A(x) \forall x \in X$
 complemento $\rightarrow \bar{A} = X - A \rightarrow \mu_{\bar{A}}(x) = 1 - \mu_A(x) \forall x \in X$
 União $\rightarrow A \cup B = \text{MAX}(\mu_A(x), \mu_B(x))$
 interseção $\rightarrow A \cap B = \text{MIN}(\mu_A(x), \mu_B(x))$

Formulações genéricas:

$$\text{Triangular } \mu_A = \max \left(\min \left(\frac{x-a}{b-a}, \frac{c-x}{c-b} \right), 0 \right)$$

$$\text{Trapezoidal } \mu_A = \max \left(\min \left(\frac{x-a}{b-a}, 1, \frac{c-x}{c-b} \right), 0 \right)$$

$$\text{Gaussiana } \mu_A = e^{-\frac{1}{2} \left(\frac{x-c}{\sigma} \right)^2}$$

$$\text{Sigmoidal } \mu_A = \frac{1}{1 + e^{\frac{x-c}{b}}}$$

Lei de Morgan

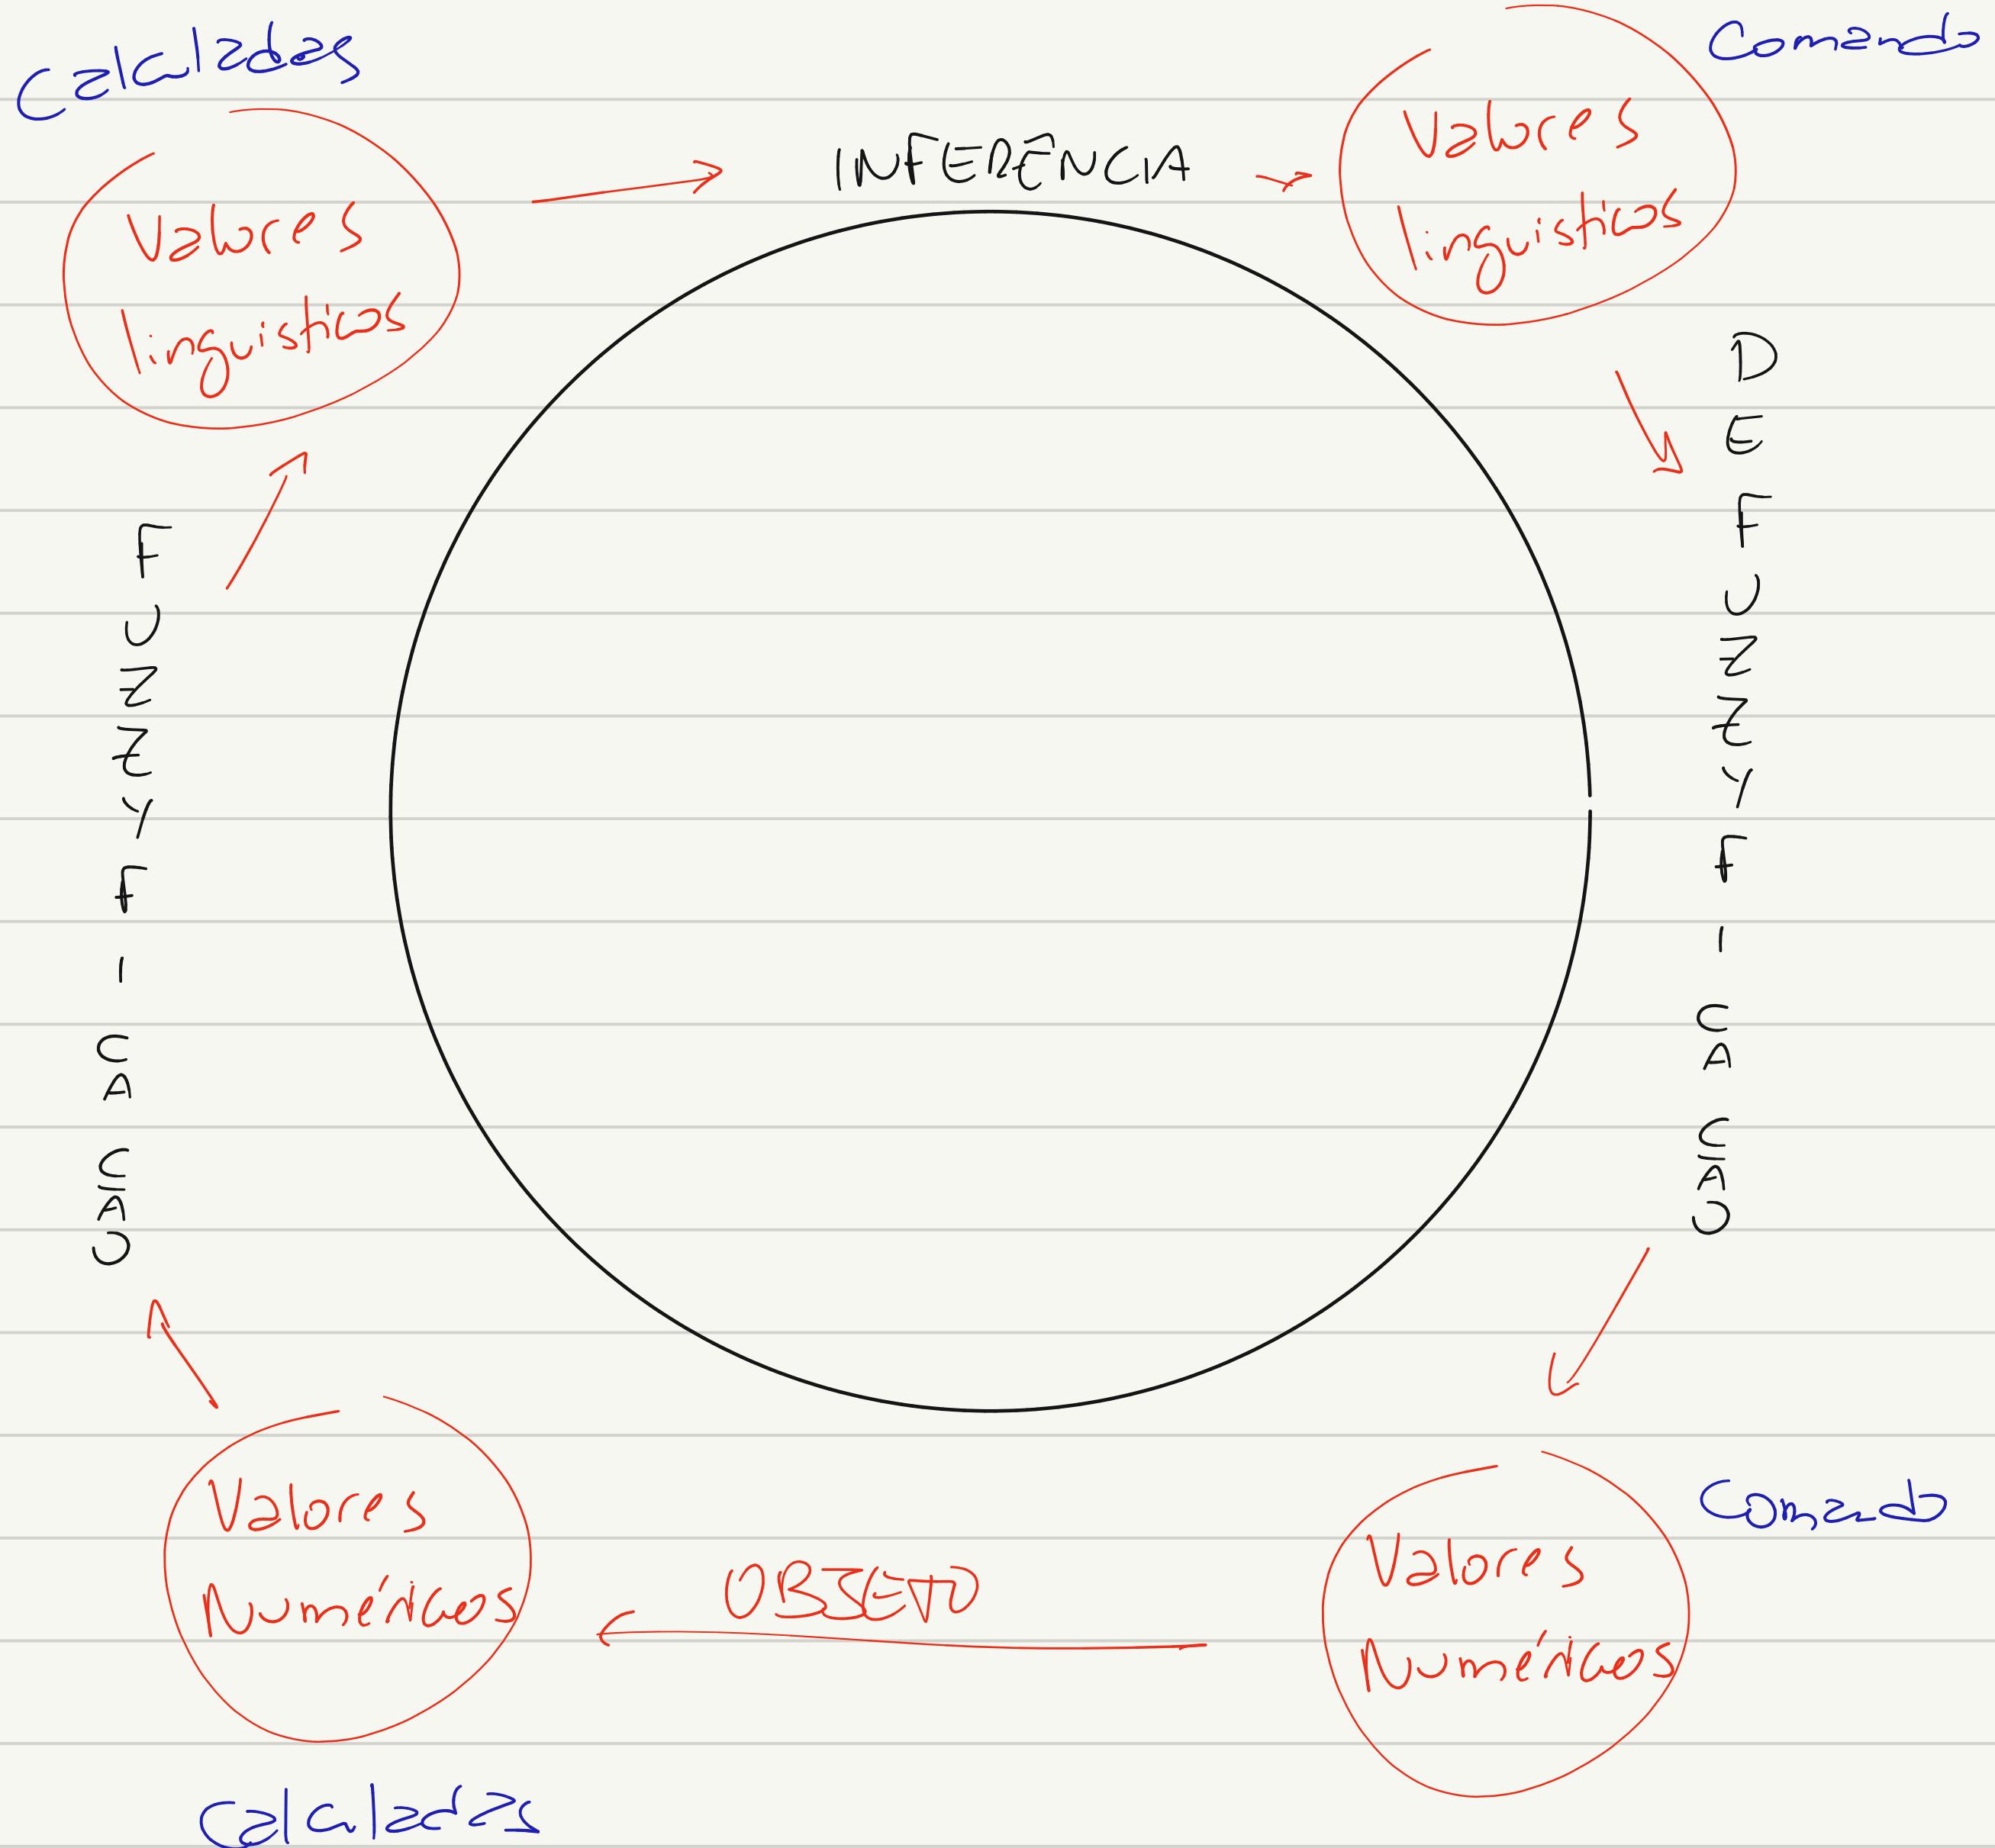
$$\rightarrow (A \vee B) = \neg A \wedge \neg B$$

$$\rightarrow (A \wedge B) = \neg A \vee \neg B$$

! CARACTERÍSTICAS QUE DISTINGUEM CONJUNTOS CLÁSICOS DE FUZZY

$$A \wedge \neg A \neq \emptyset$$

$$A \vee \neg A \neq U$$



REDES NEURAIS

IA Simbólica

- inteligência associada a um cer.
unicamente humana
- conhecimento representado por regras

IA Conexionista

- Se for construído um modelo suficientemente preciso do cérebro, esse modelo apresentará um comportamento inteligente
- conhecimento representado por exemplos

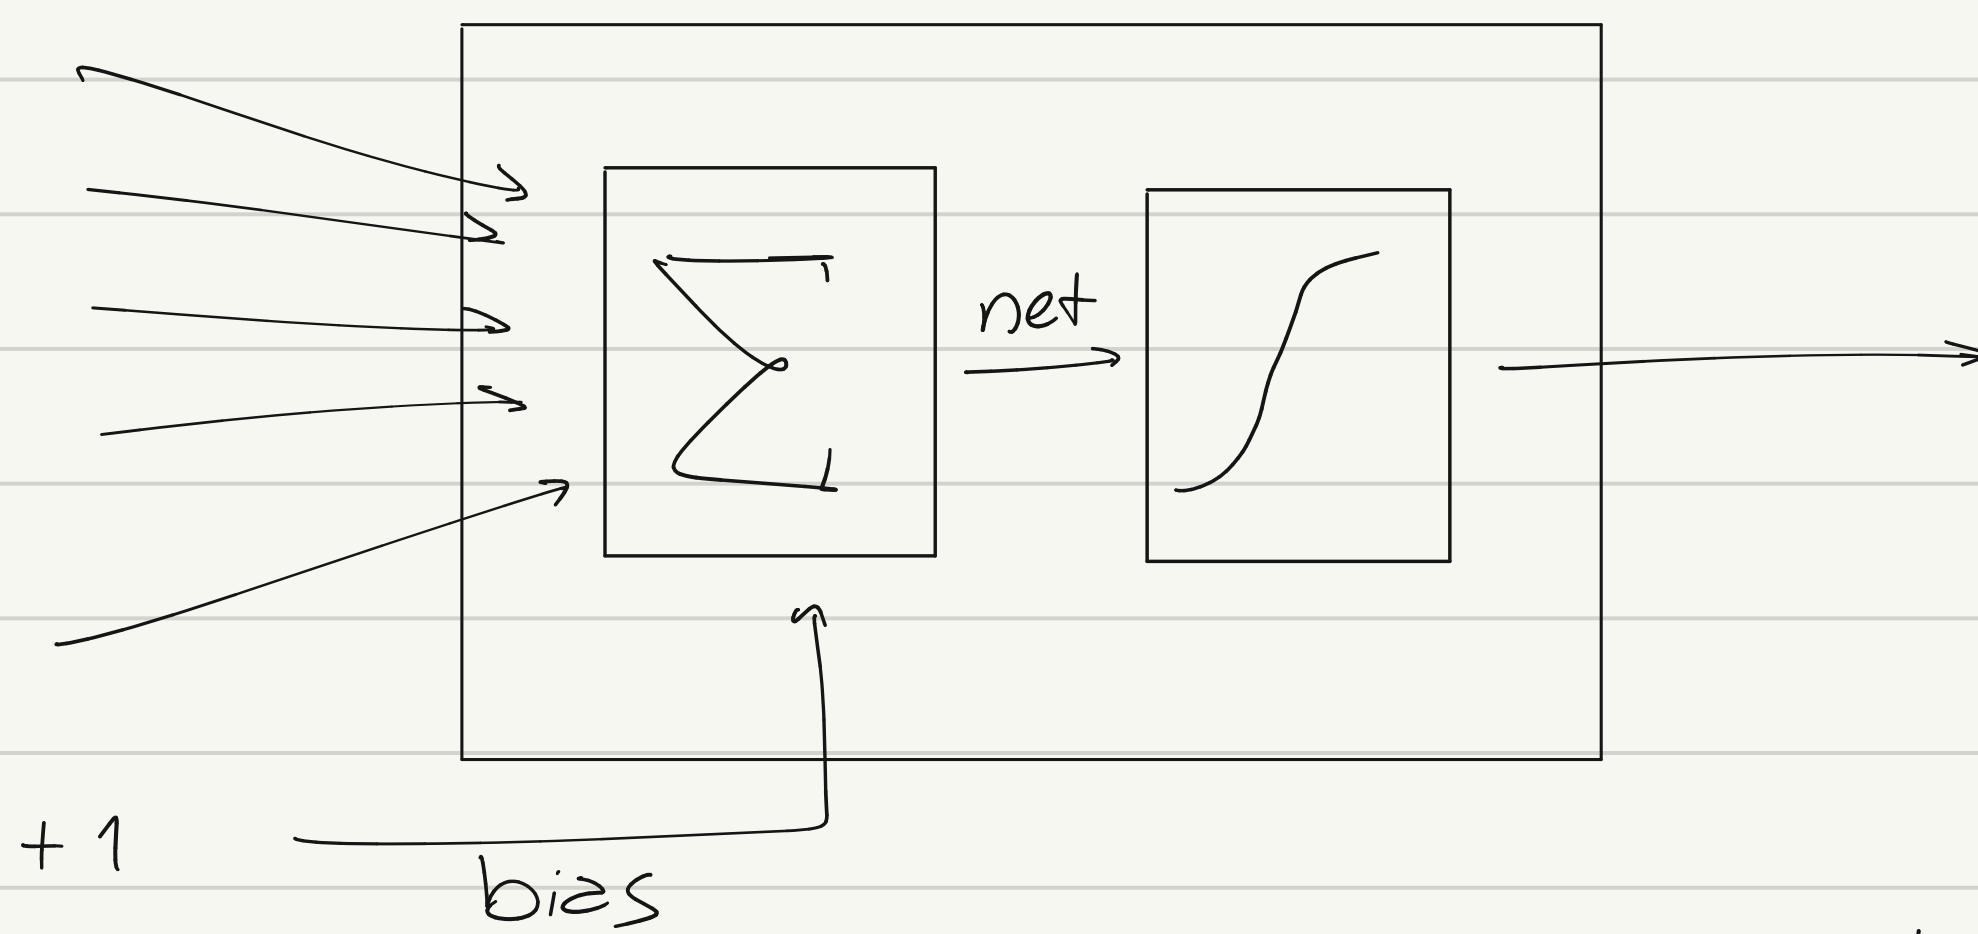
Redes Nervosas Artificiais

- Sistemas inspirados em neurônios biológicos
 - Tem comportamentos em comum com o cérebro:
 - busca paralela e endereçamento por conteúdo
 - Aprendizado
 - Associações
 - Generalizações
 - Robustez e degradação gradual

PERCEPTRON

Aprendizado: procura achar pesos de forma a minimizar a diferença entre a saída desejada e a saída obtida com o vetor de entrada
→ Regressão linear

Modelo moderno de neurônio artificial:



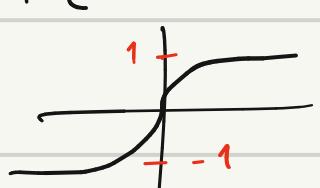
net: somatório das entradas multiplicadas por seu peso

Função de ativação (saída)

- Linear $y(x) = 2x$

- Sigmoidal $y(x) = \frac{1}{1 + e^{-kx}}$

- Tangente Hiperbólica $y(x) = \tanh(kx) = \frac{1 - e^{-kx}}{1 + e^{-kx}}$

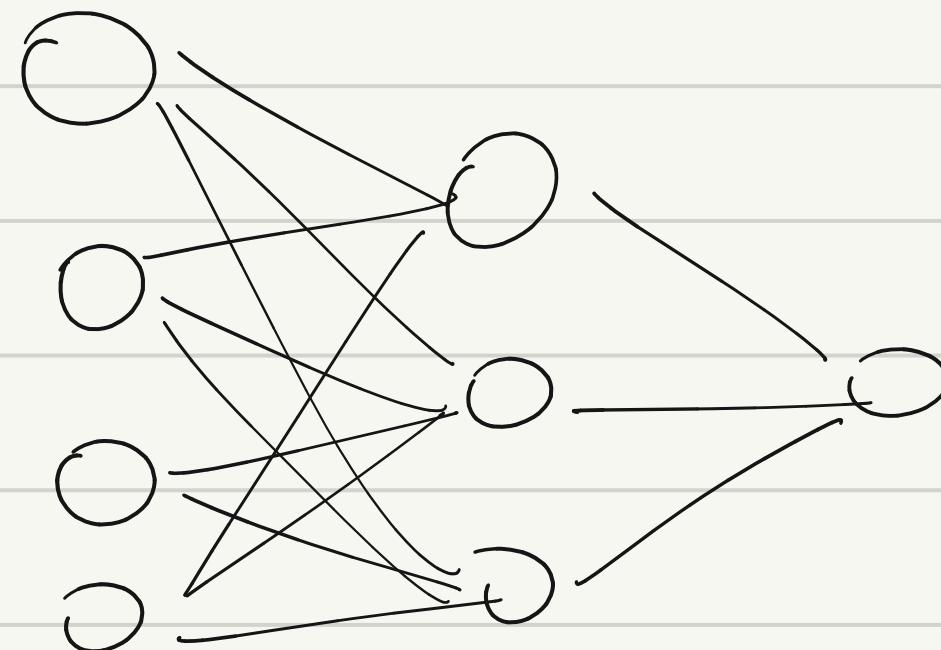


Topologias de Redes Neurais

FEED FORWARD (MLP - Multilayer perceptron)

→ Sem ciclos

- Conexões p/ frente

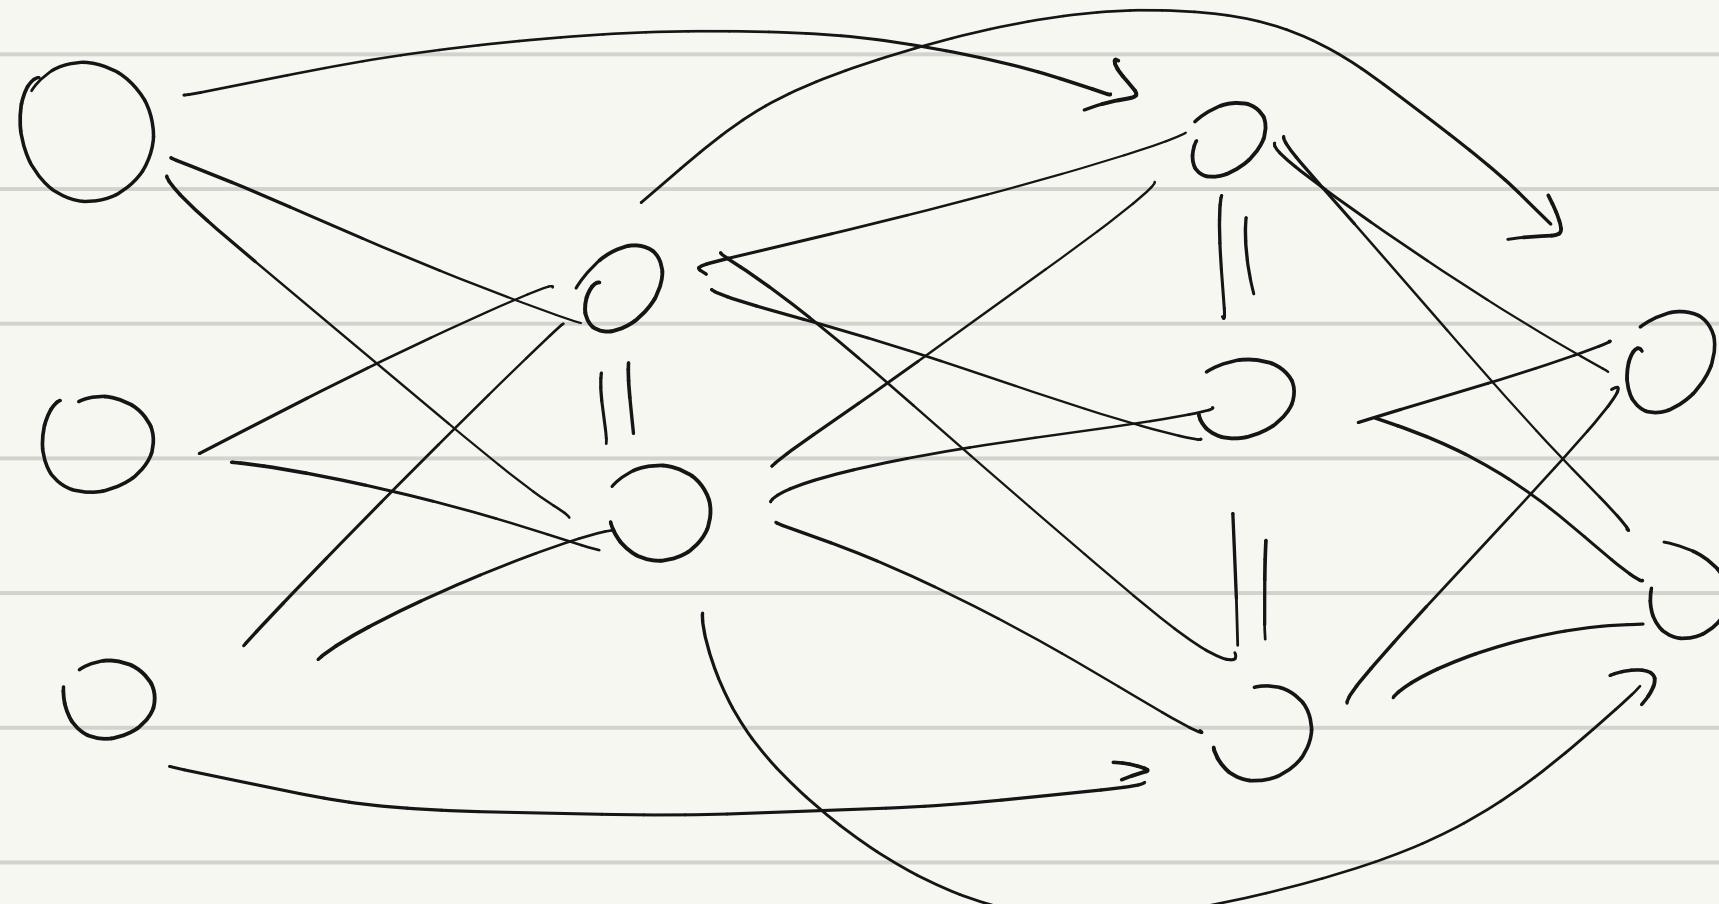


Rede de Camadas

CONCORRENTES

→ Existem ciclos

- Conexões p/ frente, trás e lados

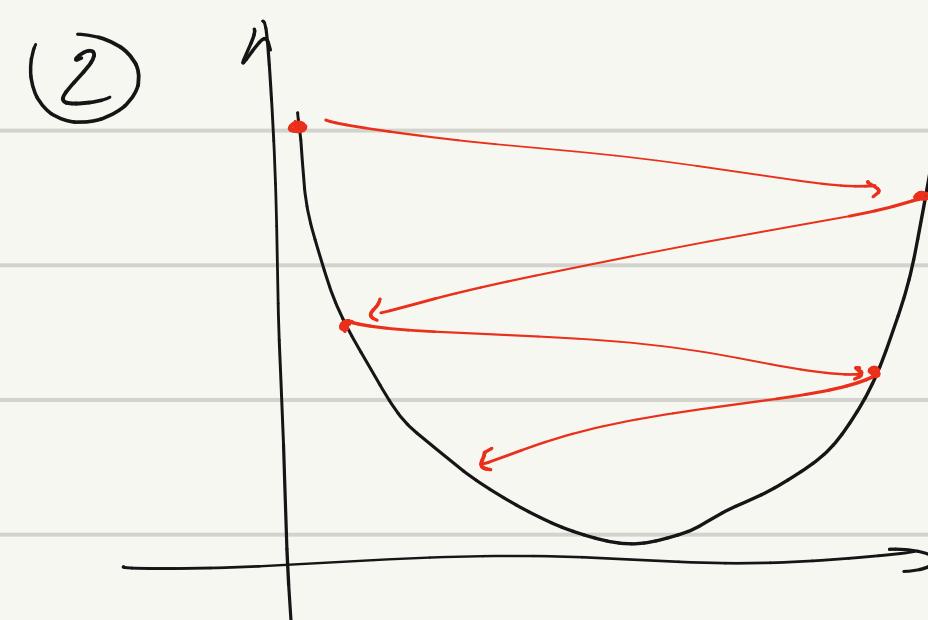
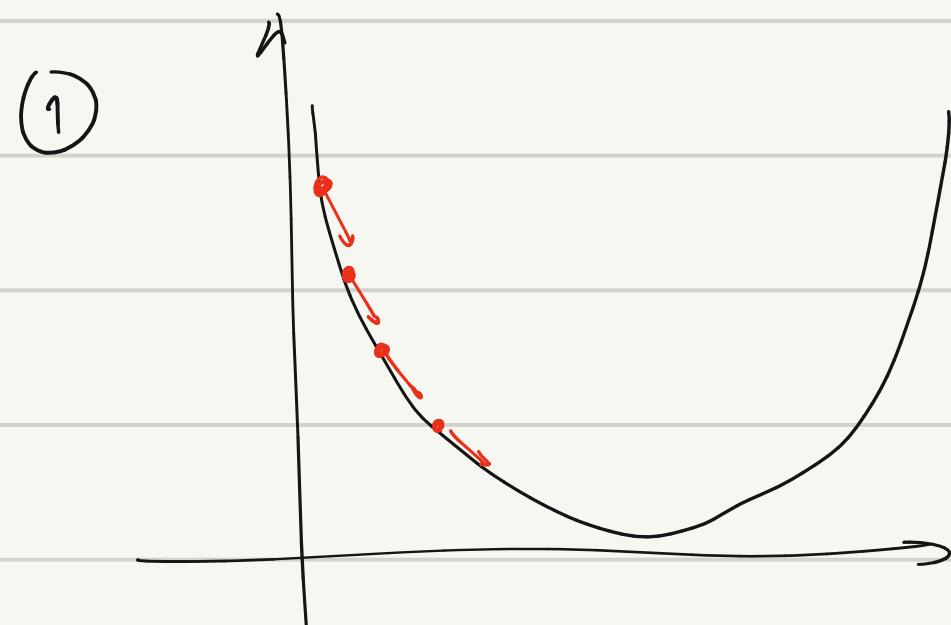


Algoritmo - Gradiante Descendente

- Deve convergir
- O update dos parâmetros devem ser feitos juntos

(1) - Se α é muito pequeno, o descendente demora

(2) - Se α é muito grande, pode falhar ou até divergir



$\alpha \rightarrow$ taxa de aprendizado

Computação Evolucionária / Evolutiva

Métodos Fortes: Para problemas genéricos em mundos lineares, continuos, etc (específicos)

Métodos Específicos: Problemas espec. em mundos espe.

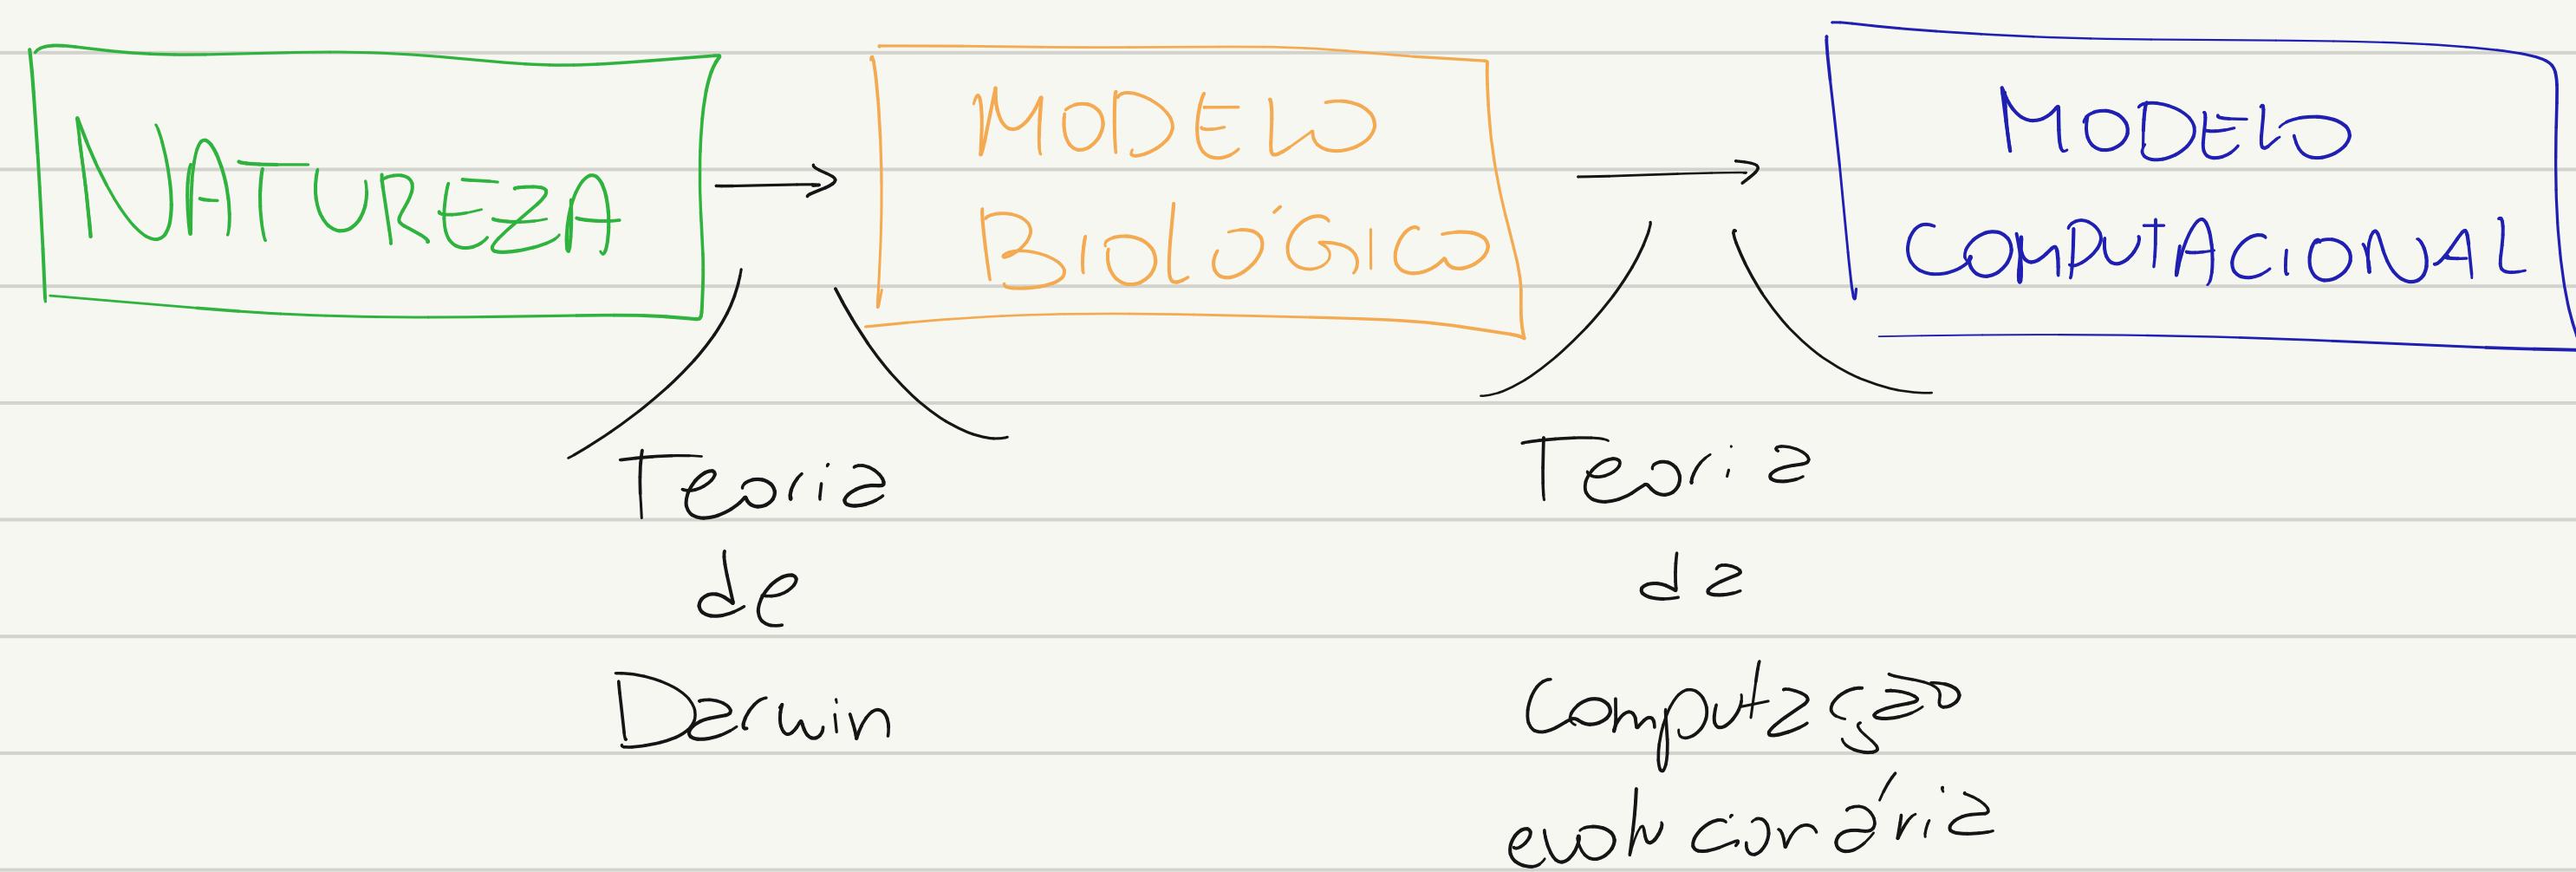
Métodos Fracos: Prob. genéricos em mundos gener.
↳ devem ser considerados sse. fortes e/ou espec.s
não existem, não se aplicam ou falham

• **Inspirada nos processos subjacentes à evolução**

1. Pop. de indivíduos moldada pela sobrevivência dos mais adaptados
2. Pressões seletivas do ambiente e também da pop.

• Pode desempenhar os papéis:

1. Ferramenta adaptativa p/ solução de problemas
2. Modelos computacional de processos evolutivos naturais

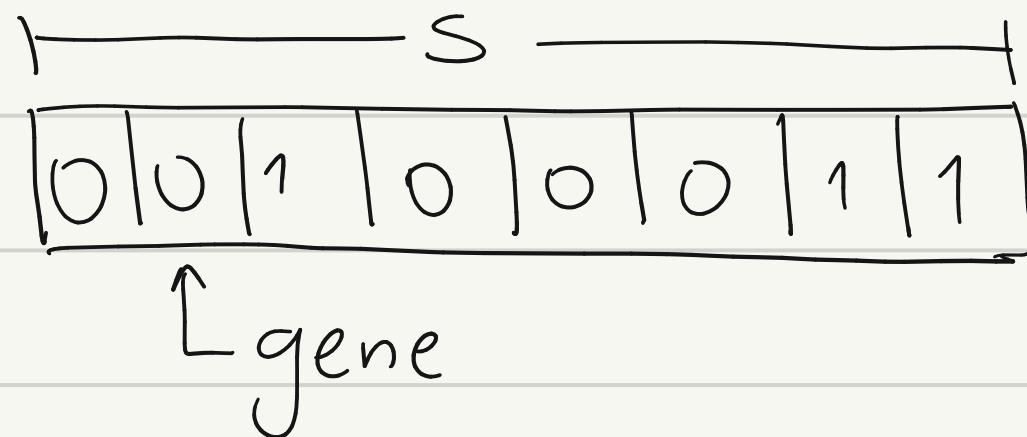


CARACTERÍSTICAS PRIMÁRIAS

- Operam em um CONJUNTO de pontos (\bar{n} a partir de um ponto isolado)
- Operam em um espaço de busca codificado, \bar{n} diretamente
- Usam transições probabilísticas, \bar{n} regras determinísticas

USO

1. Representar cada possível solução x no espaço de busca como uma sequência de símbolos s gerados a partir de um alfabeto finito A . Geralmente é o alfabeto binário $A = \{0, 1\}$
2. Cada sequência s é um cromossomo
3. Cada elemento de s é um gene



→ Na maior parte dos AG's, assume-se que um cromossomo é um indivíduo

→ Usa-se um vetor binário p_i representar cada ponto no espaço de busca.

→ O tamanho do vetor depende do uso e precisão do sistema

ex: Deseja-se uma precisão de 4 casas com um espaço de busca -2 a $+2$

→ O processo de busca vai ter:

$$\begin{array}{c} 4 \\ \hline -2 \quad -1 \quad 0 \quad 1 \quad 2 \end{array} \times \underbrace{1000}_{\substack{\longrightarrow \\ 4}} = \underline{40.000 \text{ pontos}}$$

Logo, são necessárias sequências binárias de 16 bits ($2^{15} < 40.000; 2^{16} > 40.000$)

$$2^{16} = \underline{65.536}$$

→ O intervalo de busca é dividido em 65.536 espaços iguais

Fluxo Básico

1. Cria população inicial

2. Avalia

2.1 Descarta indivíduos menos aptos

3. Enquanto critérios de parada não satisfeitos

3.1 Seleciona pais p/ reprodução

3.2 Realiza reprodução, recombinação e mutação

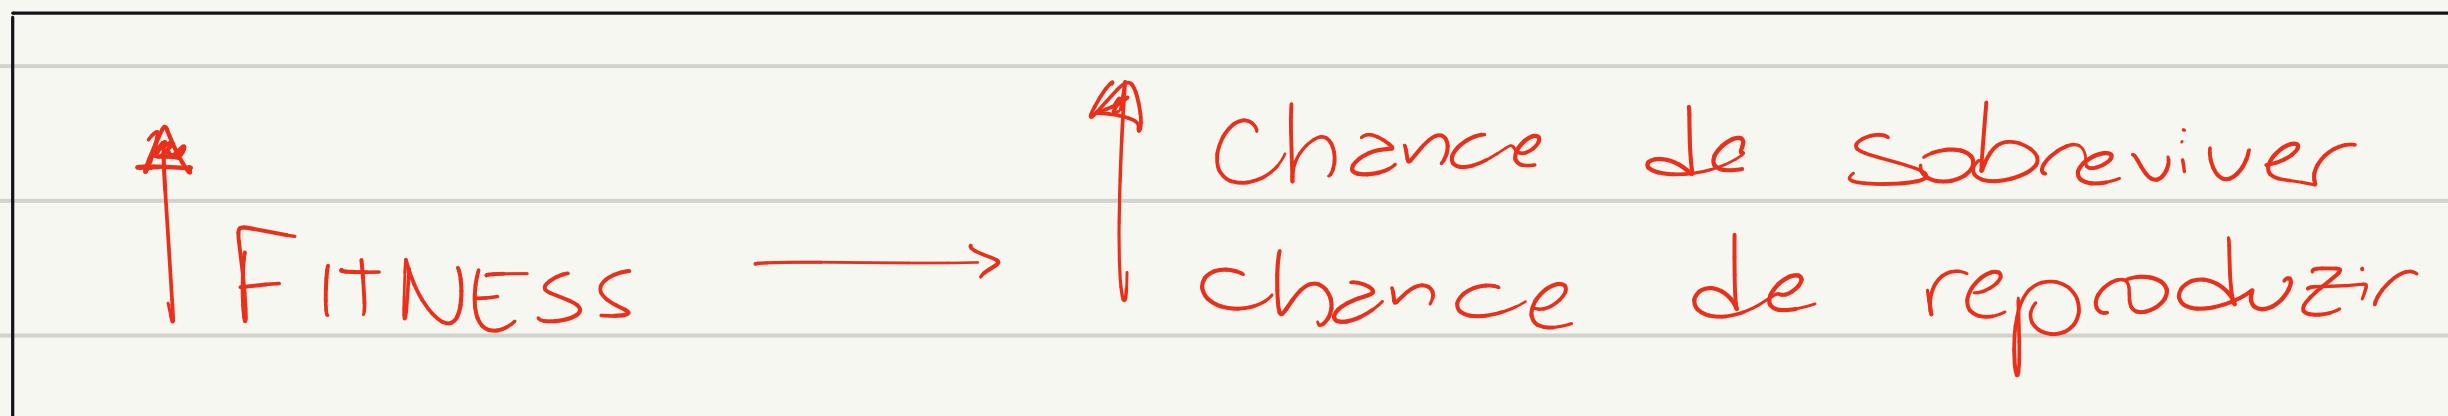
3.3 Avalia critério

→ É importante que a população inicial cubra a maior parte do espaço de busca

Avaliações e adequabilidade

É preciso uma informação de valor de uma "função objetivo" p/ cada membro da população

→ ela dá, p/ cada indivíduo, uma medida do quanto bem adaptado ao ambiente ele está → VALOR FITNESS



Seleção

Simula processos de reprod. sexuada e seleção natural

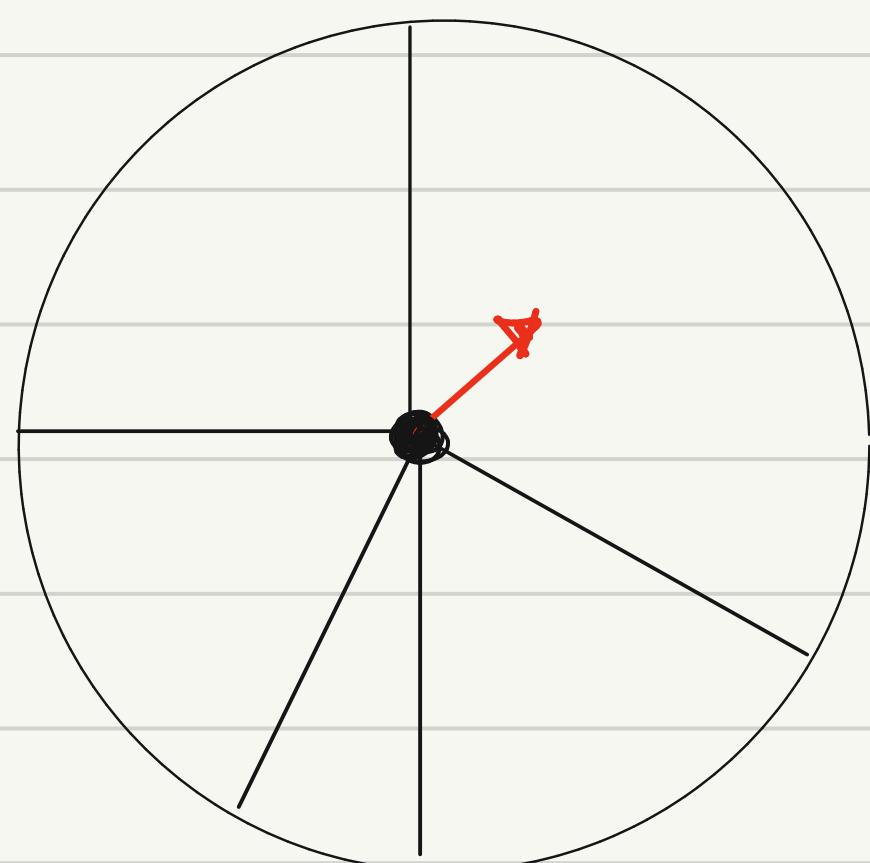
Probabilidade de Seleção de um cromossomo:

$$P(s) = \frac{f(s)}{\sum_{j=1}^{|P|} f(s_j)}$$

→ com seleção probabilística, membros fracos recebem menores chances, mas não são diretamente eliminados

- É importante que alguns candidatos menos aptos sobrevivam, pois eles ainda podem conter algum componente essencial de uma solução.

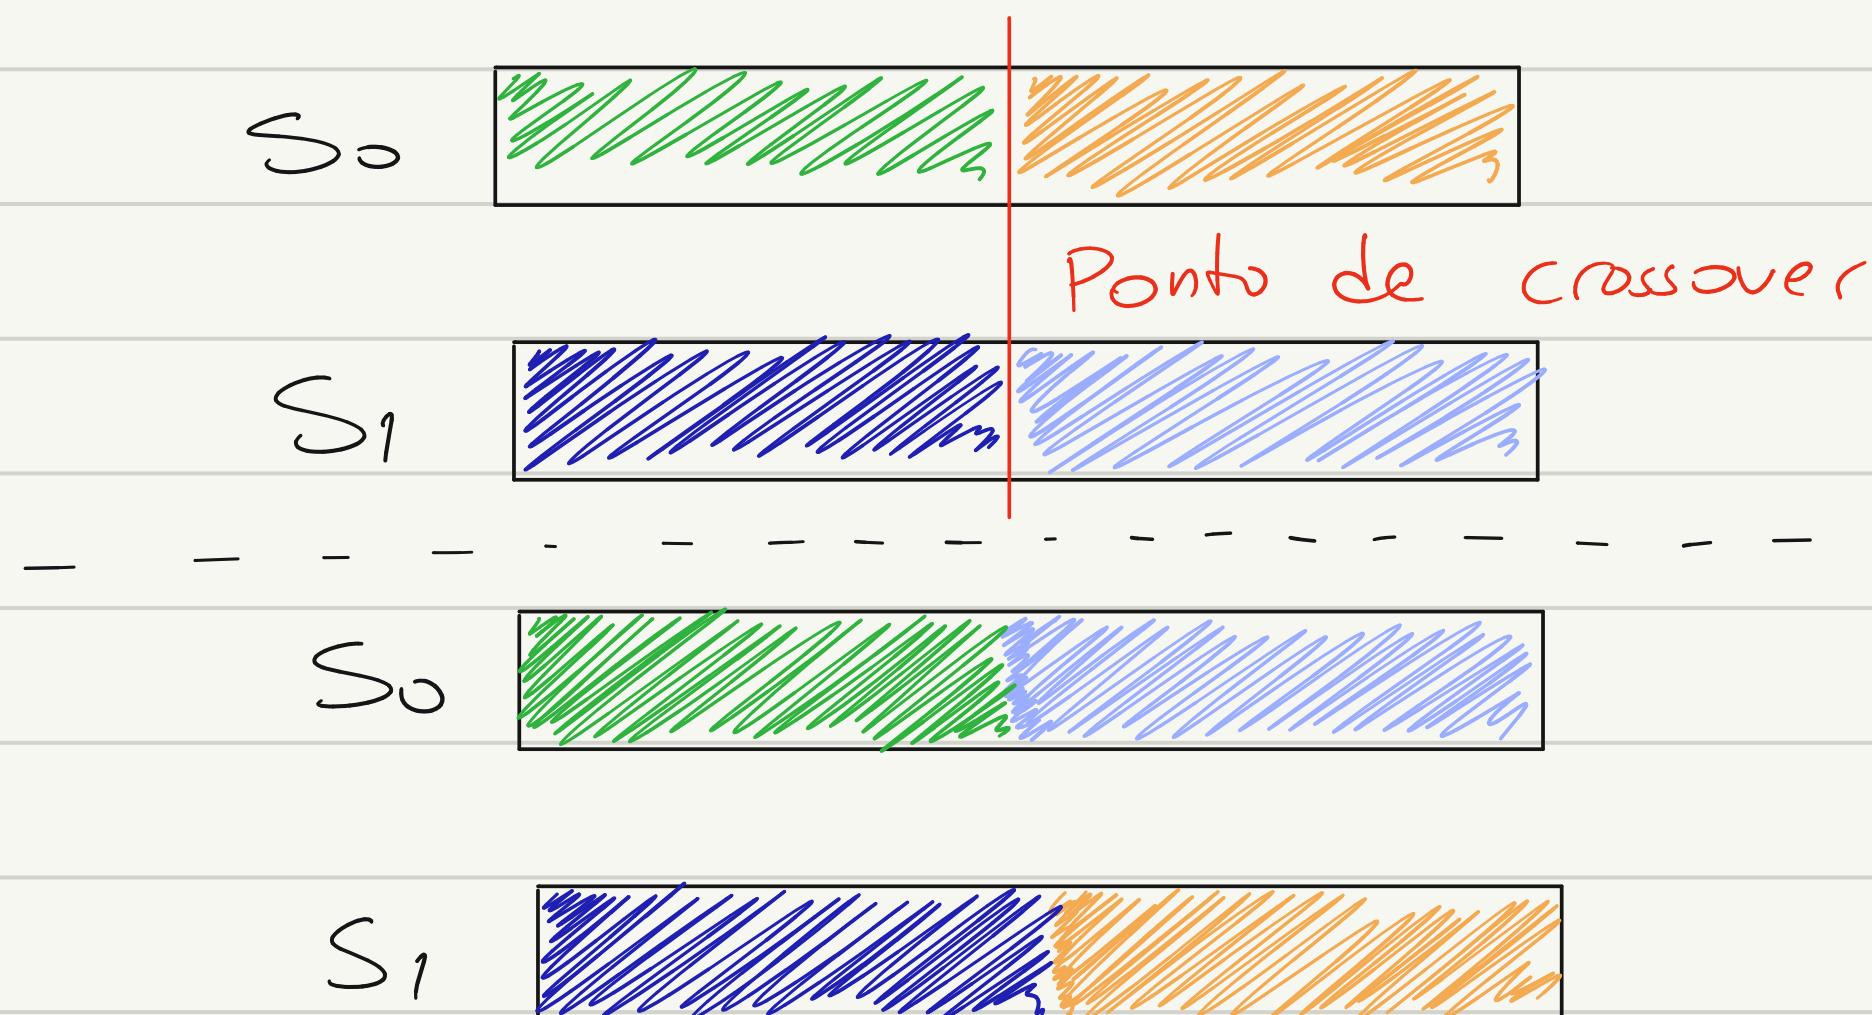
Seleção por roleta (usado nos pais)



- O tamanho dos setores é proporcional aos valores de fitness de cada indivíduo

Recombinação (cross over)

- Processo sexuado (+ de 1 indivíduo)
- emula o fenômeno de crossover (troca de fragmentos entre pares de cromossomos)
- Sua forma mais simples usa uma probabilidade fixa previamente definida pelo usuário



Mutação

- Equivalente à busca aleatória
- É selecionada uma posição no cromossomo e muda-se o valor do gene para outro aleatório (aleatoriamente)
- Processo geralmente controlado por um parâmetro fixo P_{mut} (prob. de sofrer mutação)

Mutação

Quebra = estacionariedade

Condições de término

- ponto ótimo descoberto
- número máximo de gerações
- tempo limite
- estagnação